# 面向固定翼无人机自主获能滑翔的轨迹条件能量空间观测器

## 基于轻量时序编码与条件潜空间扩散的 TESO-Diff 原理设计（WFEF-Diff 修订版）

飞行器设计与自主控制实验室

*Autonomous Gliding and Control Lab*

研究设计稿，2026 年 8 月

**摘要**

本文针对固定翼无人机自主获能滑翔中的一个基础问题重新定义观测目标：飞行控制系统真正需要的并非任意时刻完整、精确的三维非定常风场，而是在有限历史飞行经历条件下，对周围空间“是否存在可被当前航空器实际利用的能量、以何种轨迹利用、预期净收益与风险是多少”形成可供强化学习与规划直接使用的概率状态。为此，本文在此前 WFEF-Diff“先重建风场后验、再解析生成能量场”的方案基础上提出轨迹条件能量空间观测器 TESO-Diff（Trajectory-conditioned Energy Space Observer with Diffusion）。TESO-Diff 将风场由必须完整恢复的主输出降为辅助观测和潜在成因，以一段段真实飞行轨迹的累计环境能量收益作为核心证据，通过物理尺度无量纲化、轻量轨迹编码、历史证据聚合和条件潜空间扩散，直接构造动作相关的概率获能空间后验。

本文重点解决五个问题。第一，重新推导无动力与有动力固定翼飞机统一的轨迹级能量观测量，使用真空速、位置高度、气动耗散与发动机贡献分离环境能量，其中发动机功率系数 $c_T \in [0,1]$ 作为显式状态，发动机单位质量做功率采用真空速与经过动力分离的前向推进加速度之积估计。第二，在仅依赖前向皮托管硬件的前提下，允许直接采样飞控内部融合滤波器给出的三维局部风速预估及其质量信息，但不要求网络把该估计扩展成完整风场真值。第三，以轨迹片段而非瞬时点定义获能标签 $Y_E$，允许一条最终正获能轨迹内部同时包含局部能量损失、姿态转换、下降加速和拉升等阶段，从而适配热气流滑翔、风切变动态滑翔、阵风利用以及混合获能。第四，定义核心条件表征 $C_{\mathrm{TESO}} = \{c_{\mathrm{env}}, c_{\mathrm{local}}, c_{\mathrm{trend}}, c_{\mathrm{confidence}}\}$，分别描述整体环境获能信念、局部轨迹证据、时变趋势和证据置信度，并使用飞行器尺度无量纲化与小型 aircraft token 实现跨机型泛化。第五，针对 Jetson Orin Nano 与机载强化学习共享算力的约束，采用深度可分离 TCN、轻量因果注意力、低分辨率 Energy Affordance latent grid、两尺度 3D 潜扩散、4 步以内采样与按需查询解码，避免对高分辨率风场或“位置 × 动作”全体素进行扩散。

在训练数据方面，本文给出两条互补路线：基于 Gymnasium 自定义六自由度固定翼环境进行快速大规模 CPU/GPU 向量化采样；以及基于 NVIDIA Isaac Lab / Warp 的 GPU 并行刚体与自定义气动力模型生成高吞吐轨迹。仿真器内部保留真实风场、推进力与环境做功作为训练真值，但部署模型只接收机载可获得的历史状态、飞控三维风估计、发动机功率系数和轨迹级能量证据。通过对同一历史状态执行大量反事实短时轨迹 primitive，可离线构造 TESO-Diff 的 Energy Space 标签。最终模型输出不是“风速图”，而是 $\mu_E$、$\sigma_E$、正收益概率 $p_+$、稳健获能潜力 $U_E$、建议利用动作 $a_E^*$、分布外评分与证据置

信度等直接面向自主获能滑翔决策的状态量。

**关键词：** 固定翼无人机；自主获能滑翔；轨迹条件观测器；能量空间；潜空间扩散；时序编码；发动机功率分离；Jetson Orin Nano；Gymnasium；Isaac Lab

# 1. 设计结论与对原方案的修订

## 1.1 从“风场观测器”转向“获能空间观测器”

此前 WFEF-Diff 方案的主线是“机载量测 → 三维时变风场后验 → 风场导数 → WFEF 张量 → 获能功率与风险”。该路线的优点是物理解释清晰，能够把静态上升气流、空间风切变和非定常风统一在严格的风能功率表达中；同时，它也把一个困难的气象反问题设成了后续决策成立的前置条件：只有当 $W(\boldsymbol{r},t)$、$\nabla W$ 和 $\partial_t W$ 都足够准确时，解析得到的获能场才可靠。单机沿轨迹稀疏观测天然不满足完整四维场可辨识性，而空间和时间求导还会放大局部风估计噪声。对于研究目标明确为“让无人机知道哪里值得去、怎样飞能够获得更多能量”的任务，这一中间目标可能过重。

TESO-Diff 因此不再把完整风场作为必要输出，而把问题重新表述为部分可观测环境下的**动作条件能量可供性（energy affordance）推断**。无人机最近一段时间的飞行轨迹本身是一系列主动环境试验：它在不同位置、速度、姿态、转弯率和推进功率下运动，并观测到自身机械能如何变化。若能将航空器自身可解释的气动耗散和发动机输入从总能量变化中分离，就可以得到“这一段轨迹与环境交互后真正获得了多少单位质量环境能量”的直接证据。模型要做的不是恢复所有流体状态，而是学习这些稀疏轨迹证据与未观测区域可获能结构之间的统计规律。

因此，TESO-Diff 的目标后验定义为

$$p(\mathcal{E}_{t:t+T_f} \mid \mathcal{H}_t,\, c_{\text{aircraft}}), \tag{1}$$

其中 $\mathcal{H}_t$ 是当前之前的历史轨迹与轨迹级能量证据，$c_{\text{aircraft}}$ 是低维航空器条件，$\mathcal{E}$ 不是风场，而是可被连续查询的动作条件获能空间。对任意查询 $q=(\Delta\boldsymbol{r},\Delta t,s,a,T_q)$，$\mathcal{E}$ 应给出执行短时可行动作 primitive 后的累计环境能量收益分布。

## 1.2 TESO-Diff 的核心边界

本方案作如下边界约定。

1. 不要求机载网络输出完整三维风场，也不要求显式计算 $\nabla W$ 或 $\partial_t W$；飞控内部已有的三维风速估计可以作为辅助证据输入。
2. 不把地形高程、SDF 或地形图作为第一阶段核心输入。地形可能影响风，但对获能决策属于间接先验；第一阶段优先验证仅凭航空器自身经历能否形成有用的能量空间后验。
3. 不把瞬时 $\dot{e}$ 当作唯一监督标签。核心证据是一个有限轨迹片段的累计环境能量收益 $Y_E$，允许片段内部存在正负功率交替。
4. 同时覆盖无动力与有动力固定翼。发动机功率系数 $c_T \in [0,1]$ 被显式记录，发动机做功从环境获能标签中扣除，避免模型把推进器能量误学成大气能量。
5. 输出面向 RL 与规划：给出哪里可能获能、获能不确定性、正收益概率和建议动作，而不是把风场本身作为 RL 的必要状态。
6. 扩散模型的作用是表达“有限历史证据对应多个可能的获能空间”这一后验多模态性，而不是承担全部时序特征提取。

## 1.3 与 WFEF-Diff 的结构对照

表 1 给出两个方案的直接对照。两者不是互斥关系：WFEF 的能量方程仍可用于仿真标签生成、物理一致性检查和辅助监督，但 TESO-Diff 不再把“完整恢复 $W$”设为部署路径中的必要步骤。

# 2. TESO-Diff 总体信息流与逻辑框图

## 2.1 三层任务分解

TESO-Diff 可分为三个职责清晰的层级。第一层是 Experience Encoder，回答“刚才这架飞机经历了什么”；第二层是 Belief Generator，回答“在这些证据下，周围可能存在什么样的获能空间”；第三层是 RL State Builder，回答“为了继续获能，当前位置附近哪些区域值得去、用什么动作利用、风险有多大”。这种职责划分把高频传感器处理、生成式不确定性和下游控制解耦，有利于机载实时调度。

表 1: WFEF-Diff 与 TESO-Diff 的任务定义差异

| 比较项 | WFEF-Diff | TESO-Diff |
|---|---|---|
| 主要估计对象 | 三维时变风场后验 $p(W \mid D, C)$ | 动作条件获能空间后验 $p(\mathcal{E} \mid \mathcal{H})$ |
| 核心观测 | 沿轨迹局部风矢量及协方差 | 轨迹片段状态、轨迹级 $Y_E$、飞控风估计、发动机系数与质量信息 |
| 关键中间量 | $W, \nabla W, \partial_t W$ | $C_{\mathrm{TESO}} = \{c_{\mathrm{env}}, c_{\mathrm{local}}, c_{\mathrm{trend}}, c_{\mathrm{confidence}}\}$ |
| 扩散对象 | 风场或风场残差 latent | Energy Affordance latent grid |
| 动作相关性 | 由 WFEF 解析变换后获得 | 在 Energy Query Decoder 中显式以候选轨迹 primitive 为条件 |
| 地形作用 | 强条件，SDF/粗糙度等 | 第一阶段不输入；后续仅作可选消融 |
| 主要风险 | 风场不可辨识、导数噪声、计算量 | 轨迹覆盖不足、反事实空间不可辨识、能量分离偏差 |
| 对 RL 的接口 | 风场统计 + WFEF 通道 | 稳健获能潜力、概率、风险、推荐动作，直接服务获能决策 |

图 1 给出总体架构。传感器预处理与飞控估计首先产生统一时间基准的状态流；物理无量纲化消除不同飞机尺度；轨迹片段编码器把连续时间序列压缩为少量 trajectory-energy tokens；历史编码器形成四元条件表征；条件潜扩散在低分辨率获能 latent 上生成多个后验样本；连续 Query Decoder 再按 RL 实际需要查询候选位置和候选短时轨迹，不需要把全部空间和全部动作一次性解码。

### 2.2 为什么编码器位于 Diffusion 之前

条件扩散解决的是生成问题，而不是原始传感器理解问题。若直接把几十秒、多个频率、不同量纲的 GNSS/IMU/Pitot 序列拼接到 3D U-Net 中，模型需要同时学习时间对齐、机型尺度、飞行动作语义、能量归因和空间生成，既浪费算力，也会使条件弱化。TESO 编码器先把历史数据变成结构化证据 $C_{\mathrm{TESO}}$，扩散网络只负责在这一条件下表达未观测区域的多种合理可能性。

因此，编码器与扩散的关系可写成

$$\mathcal{H}_t \xrightarrow{f_{\mathrm{enc}}} C_{\mathrm{TESO}} \xrightarrow{p_\theta(Z_E \mid C_{\mathrm{TESO}})} Z_E^{(1:K)} \xrightarrow{f_{\mathrm{query}}} \mathcal{E}^{(1:K)}(q). \tag{2}$$

其中 $f_{\mathrm{enc}}$ 是确定性或轻度概率化的历史编码器，$Z_E$ 是低分辨率 Energy Affordance latent，$f_{\mathrm{query}}$ 是快速连续查询解码器。这样的设计允许扩散以低频更新，而 Query Decoder 与 RL 以高频查询同一缓存的 latent 样本。

## 3. 机载输入变量、坐标约定与数据质量

### 3.1 基础机载量测

TESO-Diff 的第一版输入不需要地形网格。推荐的基础量测为

$$S_{\mathrm{raw}}(t) = \{\boldsymbol{p}, \boldsymbol{v}_g, V_{\mathrm{TAS}}, R_b^n, \boldsymbol{\omega}_b, \boldsymbol{f}_b, c_T, \hat{\boldsymbol{W}}_{\mathrm{FC}}, q_W\}, \tag{3}$$

其中 $\boldsymbol{p}$ 和 $\boldsymbol{v}_g$ 来自 GNSS/INS，$V_{\mathrm{TAS}}$ 是真空速，$R_b^n$ 为姿态，$\boldsymbol{\omega}_b = [p, q, r]^T$ 为机体系角速度，$\boldsymbol{f}_b$ 为 IMU 比力，$c_T \in [0, 1]$ 为发动机功率系数或归一化推进命令，$\hat{\boldsymbol{W}}_{\mathrm{FC}}$ 是飞控内部利用前向皮托管、GNSS 与惯导滤波得到的三维局部风速预估，$q_W$ 是可选的估计质量、协方差迹或健康度。

这里明确区分“硬件只安装前向皮托管”和“飞控能输出三维风估计”两个层面。单个前向皮托管直接提供的主要是空速标量，但飞控可通过运动学关系、姿态、GNSS 地速、状态滤波和机体动力学形成三维风估计。TESO-Diff 可以采样这一飞控产品，因为它是机载可获得的信息；但是该三维风估计只作为局部证据，不被视为周围空间的真值，也不要求模型对其做空间求导。

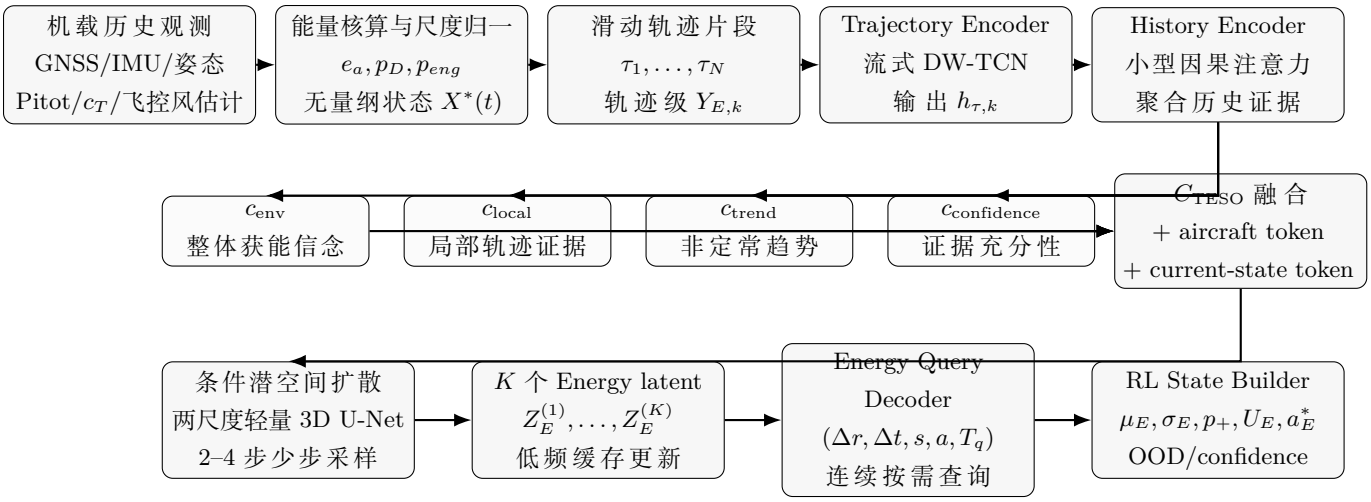



图 1: TESO-Diff 总体逻辑。上层把高频机载历史转换为轨迹–能量证据；中层形成四元 $C_{\mathrm{TESO}}$；下层扩散模型只生成低维获能空间后验，RL 高频查询缓存 latent，不要求在线完整重建风场。

### 3.2 局部坐标与航迹对齐

绝对经纬度不应成为获能空间的主要表征，否则网络可能记忆特定地点而非可迁移的环境模式。令当前时刻位置为 $\boldsymbol{p}_0$，采用局部 ENU 坐标并对水平平面做航迹对齐旋转，使当前水平航迹方向成为局部 $+x$ 轴，$+z$ 始终与重力反方向一致。对历史点

$$\Delta \boldsymbol{r}_i = R_{\chi_0}^T (\boldsymbol{p}_i - \boldsymbol{p}_0), \tag{4}$$

其中 $R_{\chi_0}$ 只绕竖直轴旋转。这样可消除不重要的绝对航向自由度，又不破坏“向上/向下”的物理意义。

### 3.3 输入变量分组

为避免网络把不同含义的量一视同仁，预处理后每个时间点建议组织为四组：

$$x_{\mathrm{kin}} = [\Delta \boldsymbol{r}, \boldsymbol{v}_g, V_{\mathrm{TAS}}], \tag{5}$$

$$x_{\mathrm{att}} = [\phi, \theta, \sin\psi_r, \cos\psi_r, \boldsymbol{\omega}_b, \boldsymbol{n}], \tag{6}$$

$$x_{\mathrm{env}} = [\hat{\boldsymbol{W}}_{\mathrm{FC}}, q_W], \tag{7}$$

$$x_{\mathrm{prop}} = [c_T, \hat{a}_{\mathrm{prop}}, q_T], \tag{8}$$

其中 $\boldsymbol{n}$ 为归一化过载/加速度相关特征，$\psi_r$ 是相对当前航向，$\hat{a}_{\mathrm{prop}}$ 为估计的发动机前向推进加速度，$q_T$ 为推进模型可信度。实际部署可按传感器可用性省略某些质量通道，但必须使用掩码或健康度区分“缺失”和“真实为零”。

## 4. 有动力与无动力统一的轨迹级能量观测

### 4.1 比机械能与轨迹累计量

TESO-Diff 不以每个时刻是否获能作为最终监督，而以一段轨迹的累计环境能量收益作为核心标签。定义相对于气团的单位质量机械能

$$e_a(t) = \frac{1}{2} V_{\mathrm{TAS}}^2(t) + g z(t), \tag{9}$$

其单位为 $\mathrm{J/kg} = \mathrm{m}^2/\mathrm{s}^2$。在长度为 $T_s$ 的轨迹片段 $\tau_k = [t_k, t_k + T_s]$ 上，直接可观测的总变化为

$$\Delta e_{a,k} = e_a(t_k + T_s) - e_a(t_k). \tag{10}$$

该变化包含大气对飞行器做功、发动机输入以及气动阻力和控制机动造成的耗散，因此不能直接把 $\Delta e_a$ 当成环境获能。

### 4.2 发动机比功率的定义

对有动力固定翼，本文采用用户给定的轻量机载定义：发动机功率系数 $c_T \in [0, 1]$ 描述当前可用推进水平；发动机对单位质量飞行器的做功率由真空速与发动机贡献的前向加速度之积得到。令

$$\hat{a}_{\mathrm{eng}}(t) = c_T(t)\, a_{\mathrm{eng,max}}(V_{\mathrm{TAS}}, h; \xi_{\mathrm{eng}}), \tag{11}$$

其中 $a_{\text{eng,max}}$ 可由静态推力试验、动力台数据或飞行辨识得到，$\xi_{\text{eng}}$ 表示电机、螺旋桨和空气密度修正参数。发动机单位质量比功率定义为

$$\boxed{\hat{p}_{\text{eng}}(t) = V_{\text{TAS}}(t)\,\hat{a}_{\text{eng}}(t)}. \tag{12}$$

若飞控或动力估计器已能直接给出“由推进产生的前向加速度” $a_{\text{eng}}$，则可直接使用式 (12)，无需显式 $a_{\text{eng,max}}$ 模型。这里不建议直接把未经分离的机体系前向 IMU 加速度 $a_x$ 代入，因为原始前向加速度同时含重力投影、阻力、阵风和姿态变化；应使用推进模型或滤波器分离出的发动机贡献项。

$c_T$ 既参与标签计算，也作为轨迹编码器输入。其作用有二：一是明确扣除推进能量，防止网络把“开大油门后机械能增加”误学成环境获能；二是使网络知道某段轨迹是在何种推进干预下获得的，从而可以识别弱环境证据与强主动推进之间的差异。

### 4.3 气动耗散与控制裕度

对常见固定翼，可用阻力极曲线近似

$$C_D = C_{D0} + kC_L^2, \tag{13}$$

并由

$$D = \frac{1}{2}\rho V_{\text{TAS}}^2 S C_D \tag{14}$$

得到阻力。单位质量耗散比功率为

$$p_D = \frac{DV_{\text{TAS}}}{m}. \tag{15}$$

在大坡度转弯、快速拉升或舵面剧烈动作下，仅以稳态极曲线估计耗散会产生系统误差，因此可以附加低维的机动损失项 $p_{\text{ctrl}}$。第一阶段不必建立复杂高保真非定常气动模型，而可把 $p_{\text{ctrl}}$ 作为小的鲁棒裕度，或利用仿真真值训练一个轻量校正网络 $f_D(V^*, n_z, |pqr|, \delta)$。重要的是：TESO-Diff 的核心并不依赖精确分解每一种阻力来源，而需要在训练和部署中使用一致的能量核算规则，并通过 $q_E$ 显式表达该规则的不确定度。

### 4.4 轨迹级环境能量标签

由能量平衡

$$\dot{e}_a = p_{\text{env}} + p_{\text{eng}} - p_D - p_{\text{ctrl}} + \epsilon_e \tag{16}$$

可得轨迹片段的环境累计收益

$$\boxed{Y_{E,k} = \Delta e_{a,k} + \int_{t_k}^{t_k+T_s} (p_D + p_{\text{ctrl}})\,dt - \int_{t_k}^{t_k+T_s} \hat{p}_{\text{eng}}\,dt} \tag{17}$$

其中 $\epsilon_e$ 表示建模和量测误差。无动力滑翔时 $c_T = 0$，式 (17) 自动退化为阻力补偿后的环境收益。对于有动力飞机，只要推进输入被正确扣除，同一个 $Y_E$ 定义仍然成立。

这一轨迹级定义对“获能滑翔”非常关键。例如一次动态滑翔循环可能先下降加速、随后穿越风切变、再转向爬升。在前半段 $\dot{e}_a$ 可能为负，但整个循环的 $Y_E$ 可以为正。若使用瞬时正负分类作为监督，模型会错误地把成功机动中的必要负收益阶段标成“坏区域”；轨迹级 $Y_E$ 则保留了获能过程的整体性。

### 4.5 标签窗口、多尺度收益与折扣

单一 $T_s$ 无法覆盖所有机制。热气流盘旋可能需要数秒至十几秒才能体现稳定收益，而穿越薄剪切层的变化更快。建议同时构造多尺度轨迹收益

$$\boldsymbol{Y}_{E,k} = [Y_E(T_1), Y_E(T_2), \ldots, Y_E(T_M)], \tag{18}$$

例如 $T_1 = 1.5$ s、$T_2 = 3$ s、$T_3 = 6$ s。第一版网络可只用 3 s 主标签，并把其他尺度作为辅助监督。若希望更贴近 RL 的长期价值，可定义带折扣的连续收益

$$Y_E^{\gamma} = \int_{t_k}^{t_k+T_s} \exp[-\lambda(t - t_k)] p_{\text{env}}(t)\,dt, \tag{19}$$

但不建议一开始就让 TESO 输出无限时域回报，因为那会把环境辨识与控制策略价值混在一起。TESO 首先应提供有限时间、可解释、与实际可执行轨迹对应的环境能量 affordance。

### 4.6 能量标签可信度

每个 $Y_{E,k}$ 必须同时记录可信度 $q_{E,k}$ 或方差 $\sigma_{E,k}^2$。误差来源包括 Pitot 比例因子、GNSS 高度噪声、推进模型误差、阻力极曲线误差、时间同步误差和快速姿态机动。可用一阶传播、蒙特卡洛传感器扰动或经验校准估计

$$\sigma_{E,k}^2 \approx J_s \Sigma_s J_s^T + \sigma_D^2 + \sigma_{\text{eng}}^2, \tag{20}$$

并定义 $q_{E,k} = \exp(-\sigma_{E,k}^2/\sigma_0^2)$。历史编码器和扩散条件都应能看到该置信度，避免高噪声片段与高质量片段获得相同权重。

## 5. 跨机型物理尺度归一与 Aircraft Token

### 5.1 为什么不能只做普通 z-score

实际固定翼平台的尺度差异很大。同样的 20 m/s 对小型滑翔机可能已接近高速状态，对更大平台却可能低于最佳滑翔速度；同样 20 m 的空间尺度，对翼展 1.5 m 的模型机与大型无人机具有完全不同的动力学意义。若仅对全数据集做均值方差标准化，网络仍可能把“飞机尺寸和速度等级”错误编码成“环境类型”，导致跨机型泛化差。

因此，TESO-Diff 在数据进入任何学习模块前先做**物理相似尺度归一**。令 $V_{\mathrm{ref}}$ 为每架飞机的特征速度，第一阶段推荐选用最佳滑翔速度 $V_{\mathrm{BG}}$；若平台没有可靠最佳滑翔速度，可使用极曲线估计值或稳态巡航参考速度。以重力 $g$ 与 $V_{\mathrm{ref}}$ 构造自然尺度

$$T_{\mathrm{ref}} = \frac{V_{\mathrm{ref}}}{g}, \tag{21}$$

$$L_{\mathrm{ref}} = V_{\mathrm{ref}} T_{\mathrm{ref}} = \frac{V_{\mathrm{ref}}^2}{g}, \tag{22}$$

$$E_{\mathrm{ref}} = V_{\mathrm{ref}}^2, \tag{23}$$

$$P_{\mathrm{ref}} = g V_{\mathrm{ref}}. \tag{24}$$

对应无量纲量为

$$\boldsymbol{r}^* = \frac{\Delta \boldsymbol{r}}{L_{\mathrm{ref}}}, \qquad t^* = \frac{t}{T_{\mathrm{ref}}}, \tag{25}$$

$$\boldsymbol{v}^* = \frac{\boldsymbol{v}}{V_{\mathrm{ref}}}, \qquad \boldsymbol{\omega}^* = \boldsymbol{\omega} T_{\mathrm{ref}}, \tag{26}$$

$$e^* = \frac{e}{E_{\mathrm{ref}}}, \qquad p^* = \frac{p}{P_{\mathrm{ref}}}, \tag{27}$$

$$Y_E^* = \frac{Y_E}{E_{\mathrm{ref}}}. \tag{28}$$

对飞控三维风估计同样采用 $\hat{\boldsymbol{W}}^* = \hat{\boldsymbol{W}}/V_{\mathrm{ref}}$。姿态角、载荷因子 $n = a/g$ 与发动机功率系数 $c_T$ 已天然无量纲。

这种归一化的目的不是声称不同飞机在严格气动相似意义下完全等价，而是先去除最显著的速度、时间、距离和能量尺度。剩余的机型差异交给一个非常小的 aircraft token 表达，从而避免把大规模平台参数直接塞进时序网络。

### 5.2 Aircraft Token

推荐的航空器条件为

$$c_{\mathrm{aircraft}}^{\mathrm{raw}} = \left[ (L/D)_{\max}, \frac{V_s}{V_{\mathrm{ref}}}, n_{\max}, C_{D0}, k, \frac{S}{m}, a_{\mathrm{eng,max}}^*, \eta_{\mathrm{prop}} \right], \tag{29}$$

其中并非所有字段都必须可得。可用 2 层小 MLP 将其编码成 $8 \sim 16$ 维

$$c_{\mathrm{aircraft}} = f_{\mathrm{air}}(c_{\mathrm{aircraft}}^{\mathrm{raw}}). \tag{30}$$

若某些参数未知，使用掩码并以机型默认值填充。该 token 不承担环境识别，只告诉 Energy Query Decoder “同一种环境对这架飞机的可利用程度如何”。

### 5.3 发动机尺度归一

推进项推荐同时保留 $c_T$ 与无量纲推进比功率

$$p_{\mathrm{eng}}^* = \frac{V_{\mathrm{TAS}} a_{\mathrm{eng}}}{g V_{\mathrm{ref}}}. \tag{31}$$

对不同飞机而言，$c_T = 0.5$ 不一定代表相同的实际推进加速度，因此仅输入 $c_T$ 还不够；$c_T$ 描述控制输入强度，$p_{\mathrm{eng}}^*$ 描述实际做功尺度，两者一起能显著降低跨平台歧义。

## 6. 轨迹分段、Trajectory-Energy Token 与历史窗口

### 6.1 为什么使用轨迹片段而非逐点样本

TESO-Diff 把每个短轨迹片段看作一次“环境交互实验”。如果历史长度为 $T_h = 20 \sim 30$ s，预处理后统一到 $f_s = 20$ Hz，则一整条序列有 $400 \sim 600$ 个时刻。直接用一个 LSTM 压缩全部历史虽然可行，但会把短时机动模式、局部能量结果和长期环境趋势混在一个隐藏状态中，而且难以让后续 Diffusion 通过 cross-attention 定位“哪一段历史证据与正在生成的空间区域最相关”。

因此采用重叠分段。设片段长度 $T_s = 3$ s、步长 $T_{\mathrm{hop}} = 1$ s，则 20 s 历史可得到约 18 个片段

$$\tau_k = \{X^*(t) \mid t \in [t_k, t_k + T_s]\}, \quad k = 1, \ldots, N. \tag{32}$$

每个片段同时附带 $Y^*_{E,k}$、$q_{E,k}$、片段中点相对位置 $\bar{\boldsymbol{r}}^*_k$ 和年龄 $\Delta t^*_k$。

### 6.2 单时刻特征向量

第一版 20 Hz 统一状态可取

$$x^*_i = [\boldsymbol{r}^*_i, \boldsymbol{v}^*_{g,i}, V^*_{\mathrm{TAS},i}, \sin\phi_i, \cos\phi_i, \sin\theta_i, \cos\theta_i, \sin\psi_{r,i}, \cos\psi_{r,i}, \boldsymbol{\omega}^*_i, \boldsymbol{n}_i, \boldsymbol{W}^*_{\mathrm{FC},i}, q_{W,i}, c_{T,i}, p^*_{\mathrm{eng},i}]. \tag{33}$$

采用三角函数表示角度可以避免 $\pi$ 与 $-\pi$ 之间的人为不连续。对于 IMU 高频原始数据，不建议全部保留到 200 Hz；可以在飞控或预处理线程计算 20 Hz 低通后的载荷因子、角速度均值、角速度 RMS 和峰值等统计量。这样既保留机动强度，又显著降低机载编码器负担。

### 6.3 Trajectory Encoder 的输入输出

令一个片段含 $L = T_s f_s$ 个时间点，输入张量为

$$X^*_k \in \mathbb{R}^{L\times d_x}. \tag{34}$$

轻量轨迹编码器 $f_\tau$ 输出

$$h_{\tau,k} = f_\tau(X^*_k) \in \mathbb{R}^{d_h}, \tag{35}$$

建议 $d_h = 48 \sim 64$。$h_{\tau,k}$ 不具有预先规定的物理维度，但希望它压缩以下信息：轨迹几何（直线、盘旋、穿越、爬升、下降）、动态状态（速度水平、加减速、转弯率、过载）、局部飞控风估计模式、发动机干预程度，以及这些状态在片段内部的时序关系。

最终的 Trajectory-Energy Token 定义为

$$z_k = \left[h_{\tau,k}, Y^*_{E,k}, q_{E,k}, \bar{\boldsymbol{r}}^*_k, \Delta t^*_k, \bar{c}_{T,k}, \bar{\boldsymbol{W}}^*_k\right]. \tag{36}$$

这里保留 $Y_E$、位置、年龄和风估计的显式低维通道，而不是强迫 $h_\tau$ 把所有信息都隐式记忆。这样既增强可解释性，也方便进行有/无飞控风估计、有/无推进信息等消融实验。

### 6.4 轨迹片段重叠的意义

重叠片段会产生相关样本，但这在在线观测中是有意的：同一次转弯或剪切穿越可以从不同起始时刻被观察，历史编码器由此获得“事件正在发生还是已经结束”的时间线索。训练集划分时应按完整 episode、风场 realization 与机型分组，不能把同一条飞行轨迹的重叠片段随机拆到训练与测试两边，否则会产生严重数据泄漏。

## 7. 四元条件表征 $C_{\mathrm{TESO}}$

### 7.1 总体定义

本文采用

$$\boxed{C_{\mathrm{TESO}} = \{c_{\mathrm{env}}, c_{\mathrm{local}}, c_{\mathrm{trend}}, c_{\mathrm{confidence}}\}} \tag{37}$$

作为 Diffusion 的核心历史条件。这四项不是简单把同一个隐藏向量切成四段，而是有不同信息职责和不同注入方式。$c_{\mathrm{env}}$ 负责全局 FiLM 条件；$c_{\mathrm{local}}$ 保留一组局部 trajectory-energy tokens 供 bottleneck cross-attention 使用；$c_{\mathrm{trend}}$ 强调最近证据的变化方向；$c_{\mathrm{confidence}}$ 调节生成后验的保守程度和观测一致性权重。

### 7.2 $c_{\mathrm{env}}$：整体环境获能信念

将 $N$ 个 token 送入小型因果历史编码器

$$H = [z_1, \ldots, z_N] \xrightarrow{f_{\mathrm{hist}}} c_{\mathrm{env}} \in \mathbb{R}^{d_e}. \tag{38}$$

推荐 $d_e = 96$。它表达“最近一段时间总体上观察到了何种可获能环境模式”，例如持续正收益、周期性正负交换、某方向穿越时收益明显、盘旋时收益增强等。$c_{\mathrm{env}}$ 不是风场参数，也不是 RL value；它只需成为预测未来 Energy Space 的充分统计特征。

为了控制算力，第一版 $f_{\mathrm{hist}}$ 不需要完整 Transformer。可采用 2 层、4 头、隐藏维 96 的因果注意力，token 数约 20，注意力复杂度很小；或者在更严格的机载配置中用单层 GRU 替代。训练阶段两者应作为消融比较。

### 7.3 $c_{\mathrm{local}}$：保留局部证据

若所有历史被压成单个 $c_{\mathrm{env}}$，生成网络在构造某个空间位置时无法直接知道“哪一条历史片段曾经过附近”。因此定义

$$c_{\mathrm{local}} = \{\tilde{z}_k\}_{k=1}^{N_l}, \tag{39}$$

其中 $\tilde{z}_k$ 为经过线性投影后的局部 token。可保留最近全部 $N \le 24$ 个 token，也可以按位置距离、时间年龄和 $q_E$ 选择最相关的 $N_l = 12 \sim 16$ 个。Diffusion 只在最低分辨率 bottleneck 做一次 cross-attention，因此不会像全层 Transformer 那样显著增加计算。

$c_{\text{local}}$ 的意义是“证据索引”。当扩散网络在生成前方某一区域 latent 时，它可以通过位置编码与 token 中的 $\bar{\boldsymbol{r}}_k^*$ 比较，优先关注空间近、时间新、质量高的片段，同时仍允许远处历史作为弱先验。

### 7.4 $c_{\text{trend}}$：环境变化趋势

获能空间是非定常的。TESO-Diff 不显式估计 $\partial_t W$，但必须保留历史证据变化。定义带时间权重的短期与长期汇聚

$$h_{\text{short}} = \sum_k \alpha_k^{(s)} \tilde{z}_k, \tag{40}$$

$$h_{\text{long}} = \sum_k \alpha_k^{(l)} \tilde{z}_k, \tag{41}$$

其中短期权重偏向最近几秒，长期权重覆盖整个窗口。趋势特征可写为

$$c_{\text{trend}} = f_{\text{trend}}([h_{\text{short}}, h_{\text{long}}, h_{\text{short}} - h_{\text{long}}]). \tag{42}$$

也可由一个 1D 深度卷积直接对 token 序列提取。其目标不是给出物理风场时间导数，而是告诉生成器：最近的正收益证据是在增强、减弱、改变方向，还是几乎稳定。

训练时可以附加一个轻量辅助任务：由 $c_{\text{trend}}$ 预测未来 $1 \sim 3$ s 内已观测航迹附近的 $Y_E$ 变化或飞控风估计变化，迫使该分支学习真正的时间演化而非静态重复特征。

### 7.5 $c_{\text{confidence}}$：证据充分性与观测可信度

概率生成模型最危险的失败不是“均值略有误差”，而是“在完全没看过的地方给出非常自信的高能区”。因此 TESO-Diff 把置信度作为一等条件。输入可包含

- 最近有效片段数量与有效历史时长；
- $q_{E,k}$、$q_{W,k}$ 的统计量；
- 历史轨迹在方向、空间位置和高度上的覆盖度；
- 相互矛盾的轨迹能量证据程度；
- 与训练分布的 embedding 距离或轻量 OOD 分数。

定义

$$c_{\text{confidence}} = f_{\text{conf}}(s_{\text{quality}}) \in [0,1]^{d_c}, \tag{43}$$

并另外输出标量 $q_{\text{obs}} \in [0,1]$。在 Diffusion 中，低 $q_{\text{obs}}$ 不应简单导致某一个确定“低能场”，而应表现为更宽的后验和更保守的最终 $U_E$。

### 7.6 条件融合方式

最终条件可写为

$$c_g = f_g([c_{\text{env}}, c_{\text{trend}}, c_{\text{confidence}}, c_{\text{aircraft}}, c_{\text{state}}]), \tag{44}$$

其中 $c_{\text{state}}$ 是当前时刻的低维状态 token。$c_g$ 通过 FiLM 或 AdaGN 调制 3D U-Net 各层；$c_{\text{local}}$ 仅在 bottleneck 做 cross-attention。这种“全局向量调制 + 单点局部注意力”的设计比把所有条件在所有空间层做注意力轻得多。

## 8. 轻量时序编码器设计

### 8.1 首选：深度可分离 Temporal Convolutional Network

为了与 Jetson Orin Nano 上的 RL 网络共享 GPU，第一版部署编码器推荐 TCN 而非大型 LSTM/Transformer。已有序列建模研究表明通用卷积序列模型可作为强力起点 [8]。TCN 使用一维因果扩张卷积，能够并行处理片段序列，且卷积核容易被 TensorRT 优化。进一步采用 depthwise-separable temporal convolution：对每个通道先做 depthwise 1D 卷积，再用 $1 \times 1$ pointwise 卷积做通道混合，使参数量和 MAC 明显下降。

推荐单片段编码器如下：

1. 线性投影：$d_x \to 32$；
2. DW-TCN Block 1：channels 32，kernel 3，dilation 1；
3. DW-TCN Block 2：channels 48，kernel 3，dilation 2；
4. DW-TCN Block 3：channels 64，kernel 3，dilation 4；
5. gated global average/attention pooling；
6. 线性输出 $h_\tau \in \mathbb{R}^{64}$。

每个 Block 包含残差、GroupNorm 和 SiLU，不使用大尺寸 LayerNorm 矩阵操作。对于 $L = 60$ 的 3 s 片段，该网络参数可控制在百万量级以下，并可对多个重叠片段共享卷积结果进一步缓存。

### 8.2 更轻的在线实现：流式 TCN 缓存

在线运行时没必要每秒从头重新卷积最近 20 s。因果 TCN 可为每层保存最后若干感受野状态，只对新到达的 20 Hz 样本增量更新。轨迹 segment 完成时从缓存状态读取 $h_\tau$。这样 Experience Encoder 的实际在线代价接近固定每步代价，而不是与历史长度成正比。

### 8.3 GRU/LSTM 作为基线

GRU/LSTM 对小序列同样可行，尤其适合最早期验证。建议设置单层 GRU，hidden 64，作为 B1 基线；双层 LSTM hidden 64 作为 B2。若 TCN 在真实异步数据上不稳定，可保留 GRU 作为机载备选，但不建议同时叠加 TCN 与 LSTM，因为这会增加参数而不一定增加可辨识信息。

### 8.4 Neural CDE 作为研究分支

Neural Controlled Differential Equation 对不规则采样、多变量时间序列有天然优势 [9]，可把异步 GNSS、Pitot 和 IMU 观测构造成连续控制路径，并让隐藏状态受新观测驱动。对于传感器丢包明显、各通道难以统一重采样的飞行数据，Neural CDE 值得作为研究对照。然而 ODE/CDE 数值求解在 Jetson 上延迟不如固定卷积可预测，因此本文不把它作为第一版机载默认，而作为“训练/离线高质量编码器”或后续蒸馏教师。

### 8.5 教师–学生蒸馏可选策略

若 Neural CDE 或更大 Transformer 在离线训练中明显优于轻量 TCN，可定义教师上下文 $C^{\text{teacher}}$ 与学生上下文 $C^{\text{student}}$，使用

$$\mathcal{L}_{\text{distill}} = \left\| c^S_{\text{env}} - c^T_{\text{env}} \right\|_2^2 + \lambda_t \left\| c^S_{\text{trend}} - c^T_{\text{trend}} \right\|_2^2 \quad (45)$$

蒸馏到机载 TCN。这样可以把复杂时序模型的归纳能力用于训练，而不把其计算成本带到飞行端。

### 8.6 历史编码器的极小化

历史 token 数通常只有 $N \approx 18 \sim 30$，因此 2 层小注意力本身并不昂贵。推荐模型维度 96、4 heads、FFN expansion 2，而不是常见 4 倍扩张；attention 只处理 token，不处理空间体素。若最终部署仍超预算，可以用“时间衰减加权池化 + 单层 GRU”替代。TESO-Diff 的多模态性主要由后面的 Diffusion 表达，不需要历史编码器本身很大。

## 9. Energy Space 的数学定义与可查询表示

### 9.1 从位置标量场改为动作条件轨迹收益场

传统“高能区”容易被误解成每个位置只有一个标量值 $E(x, y, z)$。对于获能滑翔，这是不充分的：同一个风切变位置，以不同航向、空速和爬升角穿越可能得到相反的能量变化；同一个热气流边缘，盘旋半径和转弯方向也会改变实际收益。因此 TESO-Diff 定义的原始 Energy Space 是

$$\mathcal{E}(q \mid \mathcal{H}_t), \qquad q = (\Delta \boldsymbol{r}, \Delta t, s, a, T_q), \quad (46)$$

其中 $s$ 是查询起点飞行状态，$a$ 是短时轨迹 primitive 参数，$T_q$ 是执行时长。模型输出的基本随机变量是

$$Y^q_E = \int_t^{t+T_q} p_{\text{env}}(\tau)\, d\tau, \quad (47)$$

即“从该位置与状态开始执行该 primitive 后的累计环境能量收益”，而不是瞬时功率。

### 9.2 候选动作 primitive

为了兼顾连续控制表达和训练数据可生成性，建议把动作 primitive 参数化为

$$a = [V^*_a, \gamma^*, \dot{\chi}^*, \dot{\gamma}^*, c^q_T], \quad (48)$$

其中 $V^*_a$ 是目标无量纲空速，$\gamma^*$ 是目标航迹倾角，$\dot{\chi}^*$ 是目标转弯率，$\dot{\gamma}^*$ 控制拉起/俯冲变化，$c^q_T$ 是查询动作中的推进系数。若研究目标是纯获能滑翔，可在 Query 时将 $c^q_T = 0$，但历史数据仍允许有动力阶段。实际低层飞控把 primitive 转换为舵面和油门命令，TESO 不直接输出舵量。

这种参数化有两个好处。第一，Energy Space 与具体飞控内环解耦，同一高层获能模型可迁移到不同飞机；第二，RL 可以直接把 $a$ 作为高层连续动作或候选机动描述，而不要求观测器枚举全部舵面时序。

### 9.3 为何不直接构造 $N_xN_yN_zN_a$ 高维体素

若空间网格为 $32\times32\times16$，动作离散为 32 种，再加 3 个预测时间，原始张量已经超过 150 万个标量；若 Diffusion 在每一步都处理该张量，机载代价过高。更重要的是，动作本质连续，强行离散会造成分辨率与算力的矛盾。

因此采用**低分辨率 Energy Affordance latent grid + 连续 Query Decoder**。扩散模型只生成

$$Z_E \in \mathbb{R}^{N_x^l\times N_y^l\times N_z^l\times C_l}, \tag{49}$$

推荐第一版 $N_x^l = N_y^l = 12\sim16$、$N_z^l = 6\sim8$、$C_l = 8$。它不是最终能量值，而是空间中与可获能性相关的潜在局部特征。对查询位置 $\Delta\boldsymbol{r}_q$ 做三线性插值得到局部 latent $z_E(\boldsymbol{r}_q)$，再与动作、未来时间、当前状态和 aircraft token 一起送入小型 MLP：

$$\hat{Y}_E^q = f_{\text{query}}\left[z_E(\boldsymbol{r}_q), \Delta t_q^*, s_q^*, a_q, c_{\text{aircraft}}\right]. \tag{50}$$

这样空间生成与动作查询解耦。Diffusion 每次只更新几千到几万 latent 值，而 RL 每个控制周期只对几十或几百个候选 query 执行轻量 MLP。

### 9.4 Energy latent 的坐标范围

为了跨机型复用统一网格，建议所有空间边界使用第 5 节的 $L_{\text{ref}}$ 归一。示例局部域为

$$\Omega^* = [-8,12]\times[-10,10]\times[-4,8], \tag{51}$$

即前向距离略大于后向距离。对应实际米制范围自动随 $V_{\text{ref}}$ 缩放。若小型滑翔机 $V_{\text{ref}}$ 较低，空间域自然较小；高速平台空间域自然扩大。实际范围应根据 RL 的规划 horizon 与飞机最小转弯半径冻结，而不是固定套用本文示例。

### 9.5 从多个样本形成 RL 状态

对 $K$ 个 Energy latent 后验样本 $Z_E^{(k)}$，Query Decoder 得到

$$Y_{E,k}^q = f_{\text{query}}(Z_E^{(k)}, q). \tag{52}$$

于是

$$\mu_E(q) = \frac{1}{K}\sum_{k=1}^{K} Y_{E,k}^q, \tag{53}$$

$$\sigma_E^2(q) = \frac{1}{K-1}\sum_{k}(Y_{E,k}^q - \mu_E)^2, \tag{54}$$

$$p_+(q) = \frac{1}{K}\sum_{k}\mathbf{1}[Y_{E,k}^q > 0]. \tag{55}$$

对空间位置 $r$ 的稳健获能潜力定义为

$$U_E(r) = \max_{a\in\mathcal{A}(s)}\left[\mu_E(r,a) - \beta\sigma_E(r,a) - \lambda_u P_{\text{unsafe}}(r,a)\right], \tag{56}$$

相应建议动作

$$a_E^*(r) = \arg\max_{a\in\mathcal{A}(s)}\left[\mu_E - \beta\sigma_E - \lambda_u P_{\text{unsafe}}\right]. \tag{57}$$

$\mathcal{A}(s)$ 由失速、过载、滚转率、最大俯仰速率和高度安全约束限定。这样 RL 得到的是“有风险约束的可获能空间”，而不是鼓励飞机为了短期能量进入不可恢复状态。

## 10. Energy Space Autoencoder 与训练真值

### 10.1 为什么还需要 Autoencoder

潜扩散需要一个可学习的低维空间 $Z_E$。训练阶段可以通过仿真器获得完整环境真值，并在同一历史时刻对大量反事实 query 计算 $Y_E^{q,\text{gt}}$。我们先训练一个 Energy Field Autoencoder，使 latent grid 能够支持这些 query：

$$\mathcal{Q}_t^{\text{gt}} = \{(q_j, Y_{E,j}^{\text{gt}})\}_{j=1}^{N_q}. \tag{58}$$

Encoder $E_\psi$ 可以直接读取仿真器的隐藏环境描述（解析风场参数、CFD 体素或大量 query 样本）生成 $Z_E^{\text{gt}}$；Decoder $D_\psi = f_{\text{query}}$ 只根据 $Z_E^{\text{gt}}$ 与 query 重建 $Y_E$。部署时不运行 $E_\psi$，只有 Diffusion 生成 $Z_E$，再复用 $D_\psi$ 查询。

这种做法借鉴潜空间扩散以降低生成计算量的思想 [11]：把昂贵的环境到能量关系压缩到低维 latent，使生成模型不必直接在高分辨率输出空间采样。与图像 LDM 不同，TESO 的 decoder 是连续物理 query decoder，而不是把 latent 解码成 RGB 图像。

### 10.2 Ground Truth query 的生成

在仿真环境时刻 $t_0$，固定隐藏真实环境 realization，采样若干空间起点、初始飞行状态和动作 primitive。对每个 query，从该反事实状态向前积分 $T_q$，计算真实轨迹环境收益

$$Y^{\mathrm{gt}}_{E,j} = \Delta e_{a,j} + \int (p_D + p_{\mathrm{ctrl}})dt - \int p_{\mathrm{eng}} dt. \quad (59)$$

因为仿真器知道真实气动力、真实推进力和外部风，可以额外保存

$$Y^{\mathrm{direct}}_{E,j} = \int p^{\mathrm{sim}}_{\mathrm{env}} dt \quad (60)$$

作为核对。若两者长期不一致，说明能量核算或气动模型存在错误。训练标签应优先使用与部署计算链一致的式 (59)，并用 direct truth 做单元测试。

### 10.3 Autoencoder 损失

Query 重建损失定义为

$$\mathcal{L}_{\mathrm{query}} = \frac{1}{N_q} \sum_j w_j \rho \left( f_{\mathrm{query}}(Z^{\mathrm{gt}}_E, q_j) - Y^{\mathrm{gt}}_{E,j} \right), \quad (61)$$

其中 $\rho$ 采用 Huber，$w_j$ 对靠近零收益边界、稀有高收益和安全临界动作适度提高权重。可附加排序损失

$$\mathcal{L}_{\mathrm{rank}} = \frac{1}{|\mathcal{P}|} \sum_{(i,j)\in\mathcal{P}} \log[1 + \exp(-s_{ij}(\hat{Y}_i - \hat{Y}_j))], \quad (62)$$

其中 $s_{ij} = \mathrm{sign}(Y_i - Y_j)$。对 RL 而言，正确排序“哪一个候选动作收益更高”往往比绝对值小误差更重要，因此该损失具有直接决策意义。

### 10.4 空间正则化但不强迫平滑

Energy latent 应在相邻位置有一定连续性，但热气流边缘、剪切层和阵风前缘可能存在强变化。可对 latent 使用小权重总变分或邻域一致性

$$\mathcal{L}_{\mathrm{spatial}} = \sum_{\langle i,j \rangle} \omega_{ij} \left\| Z_{E,i} - Z_{E,j} \right\|_1, \quad (63)$$

但不建议过强平滑。更合理的是让 query decoder 同时看到动作与状态，使空间 latent 只表达环境结构，快速变化由数据决定。

## 11. 条件潜空间扩散模型

### 11.1 前向扩散与训练目标

对 Energy latent ground truth $Z_{E,0}$ 施加标准高斯前向噪声

$$q(Z_{E,\tau} \mid Z_{E,0}) = \mathcal{N}\left(\sqrt{\bar{\alpha}_\tau} Z_{E,0}, (1 - \bar{\alpha}_\tau) I\right). \quad (64)$$

轻量噪声预测网络接收

$$\epsilon_\theta(Z_{E,\tau}, \tau, C_{\mathrm{TESO}}, c_{\mathrm{aircraft}}, c_{\mathrm{state}}) \quad (65)$$

训练基础损失为

$$\mathcal{L}_{\mathrm{diff}} = \mathbb{E}_{\tau, Z_0, \epsilon} \left[ w(\tau) \left\| \epsilon - \epsilon_\theta \right\|_2^2 \right]. \quad (66)$$

也可使用 $v$-parameterization。核心要求不是追求图像生成视觉质量，而是保证生成的 latent 经 Query Decoder 后得到正确的能量分布、排序和校准。

### 11.2 轻量两尺度 3D U-Net

原 WFEF-Diff 若在 $64 \times 64 \times 32 \times T$ 三维风场上扩散，机载成本高。TESO-Diff 的 latent 仅约 $16 \times 16 \times 8 \times 8$。建议 3D U-Net 只做两尺度：

- 输入卷积：$C_l \to 32$；
- Level 0：2 个 depthwise-separable 3D residual blocks，channels 32；
- stride-2 下采样到 $8 \times 8 \times 4$；
- Level 1/bottleneck：2 个 residual blocks，channels 64；
- 仅在 bottleneck 加 1 次 $c_{\mathrm{local}}$ cross-attention；
- 上采样回 Level 0，skip connection；
- 输出噪声/速度预测，与输入同形状。

3D depthwise 卷积采用 $3\times3\times3$, pointwise 用 $1\times1\times1$。GroupNorm 组数取 4 或 8。时间步 embedding、$c_{\mathrm{env}}$、$c_{\mathrm{trend}}$、$c_{\mathrm{confidence}}$ 和 aircraft token 经 MLP 后通过 FiLM 调制每个 residual block，不在高分辨率层做注意力。

### 11.3 条件注入

全局条件生成缩放与偏置

$$[\gamma_l, \beta_l] = f_l([e_\tau, c_g]), \quad (67)$$

对特征 $h_l$ 执行

$$\tilde{h}_l = (1+\gamma_l)\odot \mathrm{GN}(h_l) + \beta_l. \tag{68}$$

局部条件只在 bottleneck 使用

$$h'_b = h_b + \mathrm{CrossAttn}(Q = h_b, K = c_{\mathrm{local}}, V = c_{\mathrm{local}}). \tag{69}$$

这种结构让模型既能获得整体环境状态，又能在空间生成时引用具体轨迹证据，但注意力计算规模限制在极小 bottleneck。

### 11.4 观测一致性引导从“风一致”改为“能量一致”

原 WFEF-Diff 在反向采样时让生成风场与轨迹风观测一致。TESO-Diff 改为直接让生成 Energy latent 能解释历史轨迹收益。对历史片段 $k$，根据其代表位置、状态和已执行 primitive 构造 query $q_k^{\mathrm{obs}}$，定义

$$\mathcal{R}_{\mathrm{obs}}(Z_E) = \sum_k \frac{\left[f_{\mathrm{query}}(Z_E, q_k^{\mathrm{obs}}) - Y^*_{E,k}\right]^2}{\sigma^{*2}_{E,k} + \epsilon}. \tag{70}$$

采样时可在最后 1–2 个去噪步做小幅 gradient guidance，或更简单地把 $\mathcal{R}_{\mathrm{obs}}$ 只用于训练后验一致性损失。考虑 Jetson 算力，默认部署不建议每一步都反向求梯度，而优先依赖条件网络；只有在证据强且生成样本偏离明显时做一次末端 latent correction。

### 11.5 飞控三维风估计的辅助作用

历史输入中的 $\hat{\boldsymbol{W}}_{\mathrm{FC}}$ 不需要被扩散解码成完整风场，但可以加入两个轻量辅助任务。第一，Trajectory Encoder 根据 $h_\tau$ 预测片段平均风估计，确保 latent 不忽略这一有价值的局部证据；第二，$c_{\mathrm{trend}}$ 预测未来极短期飞控风估计变化。对应

$$\mathcal{L}_W = \left\|\hat{\boldsymbol{W}}_{\mathrm{aux}} - \bar{\boldsymbol{W}}_{\mathrm{FC}}\right\|_1 + \lambda_{Wf}\left\|\Delta\hat{\boldsymbol{W}}_{\mathrm{aux}} - \Delta\boldsymbol{W}_{\mathrm{FC}}\right\|_1. \tag{71}$$

这使网络保留与风有关的信息，但不会把风场重建变成主任务。如果真实飞控风估计质量不稳定，可通过 $q_W$ 和随机通道 dropout 让模型学会在缺失时退化到纯轨迹能量证据。

### 11.6 Classifier-free conditioning 与缺失鲁棒性

训练时以小概率随机丢弃 $c_{\mathrm{local}}$、风估计通道、aircraft token 或部分历史片段，使模型具备传感器缺失鲁棒性。完整无条件 dropout 可用于 classifier-free guidance，但机载部署不追求很强 guidance scale，避免增加两次网络前向。更现实的方案是训练时做 conditional dropout，部署时单次条件前向采样。

### 11.7 少步采样与 Consistency Distillation

标准扩散需要几十到上百步，不适合与 RL 共享 Jetson Orin Nano。本文将“训练模型”和“机载采样器”区分：离线先训练 20–50 步噪声模型，验证后蒸馏为 2–4 步 DDIM/consistency student。Consistency Models 提供了将迭代生成压缩到一或少数几步的代表性路线 [12]。TESO-Diff 第一阶段的工程目标不是追求一步极致，而是将 $K = 4$ 个后验样本的总更新控制在可与 20–50 Hz RL 并行的低频预算内。

## 12. TESO-Diff 训练目标与分阶段课程

### 12.1 总损失

完整训练损失建议写成

$$\mathcal{L} = \lambda_q\mathcal{L}_{\mathrm{query}} + \lambda_r\mathcal{L}_{\mathrm{rank}} + \lambda_d\mathcal{L}_{\mathrm{diff}} + \lambda_o\mathcal{L}_{\mathrm{obs}} \tag{72}$$

$$+ \lambda_t\mathcal{L}_{\mathrm{trend}} + \lambda_c\mathcal{L}_{\mathrm{conf}} + \lambda_W\mathcal{L}_W + \lambda_s\mathcal{L}_{\mathrm{spatial}} + \lambda_{kd}\mathcal{L}_{\mathrm{distill}}. \tag{73}$$

不建议一开始全部同时打开。TESO-Diff 的训练应采用课程式分阶段，让每个模块先在可验证目标上收敛。

### 12.2 阶段 A：能量核算单元测试

首先不训练任何神经网络，只验证式 (17)。对无风无动力、无风有动力、均匀上升流、线性剪切、脉冲阵风等解析工况检查：

- 无风无动力时，阻力补偿后的 $Y_E$ 应接近零；
- 无风有动力时，扣除 $p_{\mathrm{eng}}$ 后 $Y_E$ 应接近零；
- 发动机系数变化不能被误判为环境收益变化；
- 环境直接做功真值与能量差分核算的一致性在离散误差范围内；

- 不同积分步长下标签收敛。

如果这些测试不通过，后续 Diffusion 会学习错误标签，模型再复杂也没有意义。

### 12.3 阶段 B：Energy Autoencoder / Query Decoder

使用仿真真值的反事实 queries 训练 $Z_E^{\mathrm{gt}}$ 与 Query Decoder，目标是证明低维 latent grid 足以表达对获能决策有用的空间结构。此时不输入历史轨迹，也不训练 Diffusion。退出条件应同时看 $Y_E$ MAE、候选动作排序准确率、高收益区域召回率与正收益分类 AUROC。

### 12.4 阶段 C：Trajectory Encoder

冻结或半冻结 Query Decoder，训练 TCN 与历史编码器，使 $C_{\mathrm{TESO}}$ 对环境类别、未来局部收益和辅助风估计具有预测力。可训练一个确定性 latent predictor

$$\hat{Z}_E = f_{\mathrm{det}}(C_{\mathrm{TESO}}) \tag{74}$$

作为强基线。只有当历史编码器能够优于“最近一次 $Y_E$ 外推”“局部 GP”或简单 MLP 时，才进入生成式后验阶段。

### 12.5 阶段 D：条件潜扩散

以 $Z_E^{\mathrm{gt}}$ 为目标训练条件扩散。关注的不只是 latent MSE，而是解码后的 energy query 分布。应定期从模型采样 $K$ 个 latent，对固定验证 queries 计算 CRPS/NLL、覆盖率和 $p_+$ Brier 分数。

### 12.6 阶段 E：末端一致性与少步蒸馏

加入历史轨迹能量一致性、传感器缺失 dropout、OOD 场景和 consistency distillation。机载学生模型必须重新评估不确定性校准，因为蒸馏会改变样本多样性。若 2 步模型的后验明显塌缩，应保留 4 步作为默认，而不是为追求极低延迟牺牲风险信息。

### 12.7 阶段 F：跨机型与真实数据适配

训练时以 aircraft token 和物理无量纲量混合多个机型。验证必须做 leave-one-aircraft-out 或至少把一类质量/翼载差异明显的平台完全留出。真实飞行适配优先更新输入归一化、推进与阻力校正、最后几层 Query Decoder 和置信度校准，不建议直接用少量真实数据大幅更新整个 Diffusion。

## 13. 训练数据生成：Gymnasium 快速路线

### 13.1 自定义六自由度固定翼环境

Gymnasium 提供标准的 `Env` 接口、可组合 wrapper 和向量化环境机制 [13]，适合构建一个不依赖复杂渲染的固定翼获能数据生成器。建议建立自定义环境 `TESOSoaringEnv-v0`，其内部状态包含位置、姿态、机体系速度、角速度、发动机状态和隐藏风场 realization；对外 observation 则严格模拟机载可获得量，避免训练时偷看真值。

仿真状态方程可写为

$$\dot{\boldsymbol{p}} = \boldsymbol{v}_g, \tag{75}$$

$$m\dot{\boldsymbol{v}}_g = \boldsymbol{F}_{\mathrm{aero}} + \boldsymbol{F}_{\mathrm{prop}} + m\boldsymbol{g} + \boldsymbol{F}_{\mathrm{ext}}, \tag{76}$$

$$\dot{R}_b^n = R_b^n[\boldsymbol{\omega}_b]_\times, \tag{77}$$

$$I\dot{\boldsymbol{\omega}}_b = \boldsymbol{M}_{\mathrm{aero}} + \boldsymbol{M}_{\mathrm{prop}} - \boldsymbol{\omega}_b \times I\boldsymbol{\omega}_b. \tag{78}$$

空气相对速度由

$$\boldsymbol{v}_a = \boldsymbol{v}_g - \boldsymbol{W}(\boldsymbol{p}, t) \tag{79}$$

得到。气动力使用升阻侧力系数表或小角度模型，推进采用 $c_T$ 控制的推力/推进加速度模型。这里的真实 $\boldsymbol{W}$ 只存在于 simulator 内部，用于计算气动力与训练真值；TESO 网络部署输入仍只允许飞控风估计 $\hat{\boldsymbol{W}}_{\mathrm{FC}}$。

### 13.2 风能环境生成器

不输入地形并不意味着训练环境只能简单。第一阶段建议组合以下可控风能结构：

1. 高斯或钟形热气流：中心、半径、峰值 $W_z$、倾斜、漂移速度和寿命随机化；
2. 多热泡叠加：包含正上升核、边缘下沉补偿区和随时间增长/衰减；
3. 线性/双曲正切剪切层：随机切变方向、高度、厚度、强度和移动速度；
4. 动态滑翔风带：多层水平风，允许剪切层弯曲、上下振荡；

5. Dryden/von Kármán 风格随机阵风作为局部扰动；
6. 均匀非定常风与脉冲 gust，用于验证 trend 分支；
7. 混合场：热气流 + 剪切 + gust，使模型不能依靠单一几何模板。

所有环境参数都按 episode 随机化，并保存真值种子。数据划分必须按 seed family 和参数区间分组，测试集中保留训练未见的组合强度与漂移速度。

### 13.3 机型与传感器域随机化

每个 episode 随机采样 aircraft profile：质量、翼面积、极曲线、惯量、最佳滑翔速度、失速速度、最大过载和推进特性。所有输入先按第 5 节无量纲化，再由 aircraft token 提供剩余差异。传感器仿真至少包括：

- GNSS 位置/速度白噪声和低频漂移；
- Pitot 比例因子、偏置和低通延迟；
- IMU 白噪声、bias random walk、姿态误差；
- $c_T$ 命令到实际推进加速度的时滞与效率扰动；
- 飞控三维风估计的滤波延迟、偏差、相关噪声和偶发失效；
- 不规则丢包、时间戳抖动和不同采样率。

模型只能接收这些带误差的“机载量”，而标签生成器可访问无噪声隐藏状态。

### 13.4 飞控三维风估计模拟

为了与真实系统一致，仿真中不要把真风直接赋给 $\hat{\boldsymbol{W}}_{\mathrm{FC}}$。应实现一个简化的飞控估计器，例如以

$$\hat{\boldsymbol{W}}_{\mathrm{raw}} = \boldsymbol{v}_g - R_b^n \hat{\boldsymbol{v}}_a^b \tag{80}$$

为测量，再通过 EKF/低通滤波和动力学约束产生三维风估计。即使 $\hat{\boldsymbol{v}}_a^b$ 只由前向 Pitot 加姿态/攻角先验构造，也要通过误差模型让仿真反映真实偏差。训练时随机化该估计器参数，使 TESO 不会过拟合某一套风估计算法。

### 13.5 轨迹来源：不只使用随机控制

如果训练轨迹只由完全随机舵量生成，大量样本会处于失速或无意义状态；如果只由最优控制器生成，又会缺少反事实覆盖。建议混合四类轨迹：

1. 安全随机 primitive：在可飞包线内随机直飞、转弯、爬升、下降和速度目标；
2. scripted soaring：热气流盘旋、剪切穿越、动态滑翔典型循环；
3. curriculum RL/exploration policy：随着训练进展产生更复杂策略；
4. adversarial/coverage policy：专门去历史稀疏区域或尝试信息增益机动。

这样 history encoder 既看到成功获能，也看到失败、退出和混合轨迹，避免 $Y_E > 0$ 样本极端不平衡。

### 13.6 Gymnasium 向量化采样

Gymnasium 的自定义环境可通过 `gymnasium.make_vec()`、`SyncVectorEnv` 或 `AsyncVectorEnv` 并行多个 episode。由于 TESO 数据生成主要是数值 6-DOF 与解析风场，不需要图形渲染，因此一台工作站可运行大量无头环境。每个环境每隔固定 simulation step 记录机载观测，同时在后台维护真实环境状态。

数据记录分两条流：

1. **Experience stream**：保存真实部署可见的 $S_{\mathrm{raw}}(t)$，用于构造历史 $\mathcal{H}_t$；
2. **Counterfactual label stream**：在选定锚点 $t_0$ 暂停/复制环境状态，对大量 query $(r, a, T_q)$ 做短 rollout，生成 $Y_E^{q,\mathrm{gt}}$ 和 $Z_E^{\mathrm{gt}}$。

第二条流只用于离线训练，真实飞机当然无法在同一时刻并行尝试几百条轨迹。正是这种仿真反事实 supervision 让模型学会从“一条已飞历史”推断“未飞区域的多种可能收益”。

## 14. 训练数据生成：NVIDIA Isaac Lab / Warp 路线

### 14.1 为什么需要 NVIDIA 路线

Gymnasium 自定义数值环境非常适合快速验证 TESO 原理，但当需要大规模并行、GPU 上批量执行 6-DOF、自定义气动力、传感器随机化以及与后续 RL 训练共用环境接口时，可以使用 NVIDIA Isaac Lab 或 Warp。Isaac Lab 提供基于 Gymnasium 风格接口的 vectorized environment[14]，Manager-based/Direct workflow 可组织 observation、action、

**Algorithm 1** Gymnasium 环境中的 TESO-Diff 数据生成

**Require:** 机型分布 $P(A)$, 风能环境分布 $P(W)$, 历史长度 $T_h$, query 数 $N_q$

**for** 每个并行 episode **do**
  随机采样 aircraft profile 与隐藏风能场 realization
  初始化传感器偏差、飞控风估计器与推进模型
  **while** episode 未终止 **do**
    由安全随机/脚本/RL 策略产生高层 primitive 和 $c_T$
    积分 6-DOF 动力学并生成有噪机载量测
    更新飞控三维风估计 $\hat{\boldsymbol{W}}_{\mathrm{FC}}$
    记录 history stream，并在线计算滑动 $Y_{E,k}$
    **if** 到达 Energy Space 标注锚点 **then**
      保存隐藏 simulator snapshot
      **for** $j = 1$ to $N_q$ **do**
        采样反事实位置/状态/primitive $q_j$
        从 snapshot 分叉并向前 rollout $T_q$
        计算 $Y^{\mathrm{gt}}_{E,j}$、安全标签与 direct environment work
      **end for**
      保存 $(\mathcal{H}_t, \mathcal{Q}^{\mathrm{gt}}_t, \text{aircraft})$
    **end if**
  **end while**
**end for**

randomization、reward 与 termination；Warp 则允许把 Python 形式的计算内核 JIT 编译为 CUDA kernel[16]，非常适合把成千上万个固定翼动力学和解析风场计算并行化。

需要强调：Isaac Lab/Isaac Sim 并不会自动提供满足本课题需求的固定翼气动与热气流模型。TESO 数据生成仍需自己实现 $\boldsymbol{F}_{\mathrm{aero}}$、$\boldsymbol{M}_{\mathrm{aero}}$、推进和风场采样，再通过刚体外力/力矩接口作用到航空器。选择 NVIDIA 路线的价值主要是并行执行、GPU 管线、场景管理和 domain randomization，而不是依赖通用刚体引擎替代空气动力学。

### 14.2 Direct workflow 与 Manager-based workflow 的选择

若目标只是高速生成 TESO 轨迹数据，推荐先采用 Isaac Lab Direct workflow 或直接 Warp kernel：所有动力学、观测和标签逻辑集中在少量函数中，开销最小。若后续需要与 RL 任务、随机化事件、传感器管理和多个控制器长期共用，则可迁移到 ManagerBasedRLEnv，把以下功能拆分为 managers：

- Observation：机载量、飞控风估计、TESO 输出；
- Action：舵面/高层 primitive/$c_T$；
- Event：机型、推进效率、传感器 bias、风场 realization 随机化；
- Reward：后续 RL 的航时/能量/安全目标，不参与 TESO 本体监督定义；
- Termination：失速、触地、超包线、出界。

TESO 训练数据生成与 RL 策略训练可以共享同一 environment state，但数据集构造时必须把 “TESO 的真实标签” 和 “RL 的 reward” 分开保存，避免目标混淆。

### 14.3 Warp GPU kernel 数据生成

对纯数值大规模采样，可以把每个并行航空器实例映射到一个或一组 Warp threads。核心 kernel 包括：

1. sampleWind：输入位置、时间和随机场参数，返回隐藏真实风；
2. aeroForce：根据相对气流、姿态、舵量和 aircraft profile 计算气动力矩；
3. propulsion：根据 $c_T$、空速、高度和随机化效率计算推进力/加速度；
4. integrate6DoF：批量积分平动与转动状态；
5. sensorModel：生成 Pitot/GNSS/IMU 噪声与延迟状态；
6. energyLabel：批量计算 $e_a$、$p_D$、$p_{\mathrm{eng}}$ 与轨迹 $Y_E$；
7. counterfactualRollout：从相同 snapshot 对 $N_q$ 个 primitives 并行 rollout。

这种架构特别适合 TESO，因为最昂贵的数据标注步骤恰恰是 “同一历史条件下并行尝试很多反事实短轨迹”。与逐个 Python environment 循环相比，GPU kernel 可把 $B \times N_q$ 个 rollout 一次调度。

### 14.4 Isaac Lab 中的 Domain Randomization

Isaac Lab Event Manager 支持 startup、reset、interval 等随机化时机。TESO 可在 reset 时随机机型/质量/推进效率/传感器偏置/风场家族，在 interval 时随机 gust、飞控风估计失效或推进效率缓慢变化。这里的随机化目标不是让 RL 政策“变鲁棒”这么简单，而是让 TESO 学到：当航空器、传感器和环境都变化时，$C_{\mathrm{TESO}}$ 中哪些模式仍与可获能空间稳定相关。

### 14.5 仿真 fidelity 的层级

建议不要一开始就追求复杂 CFD 在线耦合，而采用三级 fidelity：

1. F1：解析风能场 + 低阶 6-DOF，生成百万级样本，验证架构与不确定性；
2. F2：复杂时变合成场/预计算 LES、WRF 或 CFD 切片 + 高质量气动系数表，覆盖热气流、剪切、山波样结构和阵风；
3. F3：真实飞行日志与少量高保真数字孪生，对推进、传感器和 $Y_E$ 校准。

TESO 的关键是轨迹条件与能量监督，并不要求训练数据生成器在每个 episode 在线求 Navier–Stokes。高保真流场可以预计算，然后在 Warp/Isaac Lab 中做快速四维插值。

## 15. 训练样本格式与数据集组织

### 15.1 单样本内容

一个 TESO-Diff 训练样本建议包含：

1. 时间基准与局部 ENU/航迹对齐坐标定义；
2. 最近 $T_h$ 的 raw/filtered GNSS、Pitot、IMU、姿态、$c_T$；
3. 飞控三维风速估计、质量/协方差与估计器版本；
4. 每个轨迹片段 $\tau_k$ 的 $Y_{E,k}$、$\sigma_{E,k}$ 与能量核算中间项；
5. aircraft profile、$V_{\mathrm{ref}}$、气动极曲线和推进模型版本；
6. counterfactual query 列表 $(q_j, Y^{\mathrm{gt}}_{E,j})$；
7. 可选 $Z^{\mathrm{gt}}_E$ 或生成该 latent 的 encoder 版本；
8. 隐藏仿真风场/外力真值仅作为 debug 与辅助监督，不进入部署 observation；
9. simulator seed、风场家族、噪声 seed 与软件版本。

所有无量纲特征应由统一后处理脚本生成，不应让不同数据源自己采用不同参考速度或能量符号。

### 15.2 数据划分原则

必须按 episode、风场 realization、机型和环境家族成组划分。推荐至少包含：

- IID test：同类参数范围的未见 realization；
- OOD-wind：未见的热气流半径/剪切厚度/漂移速度组合；
- OOD-aircraft：完全留出的 aircraft profile；
- OOD-sensor：更大的 Pitot 偏差、风估计掉线或推进效率误差；
- Mixed mechanism：训练只见单机制，测试热气流 + 剪切 +gust 混合；
- Powered/unpowered transfer：训练包含不同 $c_T$ 分布，测试长时间纯滑翔或不同推进策略。

TESO 最终若用于实际获能控制，必须证明输出不是依赖某一环境脚本的模式识别，而是对轨迹–能量关系具有一定跨分布迁移能力。

## 16. 面向 Jetson Orin Nano 的轻量化部署设计

### 16.1 算力约束的基本原则

Jetson Orin Nano 系列属于边缘嵌入式计算平台；即使最新 Super 模式提供更高 AI 吞吐，机载任务仍需与 RL 和飞控共享有限功耗与内存资源 [18]，同时机载还需运行飞控通信、状态估计、视觉/导航任务以及 RL policy。TESO-Diff 因此不应占满 GPU，也不应以“单次推理越快越好”为唯一目标，而要采用**多速率**、**缓存**、**按需查询**架构：高频部分只做便宜的轨迹更新，低频部分做生成式后验更新，RL 高频使用缓存 latent 与轻量 query decoder。

### 16.2 推荐参数预算

第一版机载模型目标建议为：

- Trajectory Encoder：$< 1$ M 参数；
- History Encoder + 四元条件头：$< 1$ M 参数；
- Energy Query Decoder：$< 0.5$ M 参数；

- 2-scale 3D latent diffusion：约 4 ∼ 8 M 参数；
- 总参数尽量控制在 10 M 左右，不把“更大 U-Net”作为默认改进方向；
- FP16 权重优先，验证后对 TCN/MLP/部分卷积尝试 INT8；对扩散归一化和敏感输出保留 FP16。

这些是设计预算而非已经测得的硬件结果，最终必须在目标 Jetson Orin Nano 电源模式、TensorRT 版本和共享 RL 负载下实测冻结。

### 16.3 多速率调度

推荐运行频率为：

- 100–200 Hz：飞控自身 IMU/姿态与三维风估计，不由 TESO 承担；
- 20 Hz：TESO 预处理、无量纲化、能量积分状态更新；
- 5–10 Hz：流式 TCN token 更新；
- 1–2 Hz：History Encoder 更新 $C_{\mathrm{TESO}}$；
- 0.5–1 Hz：低频 Diffusion 生成 $K = 4$ 个 Energy latent 后验样本；
- 10–50 Hz：RL 对缓存 latent 使用 Query Decoder 查询候选动作，或直接读取预计算低维 $U_E$ 通道。

这样 Diffusion 延迟不会直接阻塞 RL control loop。即使某次生成更新超时，系统仍可继续使用上一版本 latent，并通过 age/confidence 降低其权重。

### 16.4 缓存与增量计算

部署端保存：

1. TCN 每层的因果卷积历史缓存；
2. 最近 $N$ 个 trajectory-energy tokens；
3. 当前 $C_{\mathrm{TESO}}$；
4. 最近 $K$ 个 Energy latent 样本；
5. RL 常用 query 格点的上次 $\mu_E, \sigma_E, p_+$。

只有当新 token 使 $c_{\mathrm{env}}$ 或 $c_{\mathrm{trend}}$ 变化超过阈值、或 latent 年龄超过上限时，才强制触发 Diffusion 更新。环境稳定时可降低生成频率，把 GPU 留给 RL；环境快速变化时由 $c_{\mathrm{trend}}$ 提高更新频率。

### 16.5 TensorRT 部署

TCN、history encoder、3D U-Net 和 Query MLP 均应导出 ONNX/TensorRT。固定 shape 往往比完全动态 shape 更容易获得稳定最优 kernel，因此建议把历史 token 数、latent grid 和 batch queries 设为少数几个固定 profile，例如 query batch 32/64/128。TensorRT 支持 optimization profile 管理动态输入 [17]，但不同 profile 会影响内存与 tactic，因此机载版应尽量限制 shape 种类。

### 16.6 异步 GPU stream 与 RL 并行

TESO Diffusion 可以在独立 CUDA stream 低优先级执行；RL policy 维持高优先级小 batch 推理。系统线程结构建议分为 Sensor/Preprocess、TESO Encoder、TESO Diffusion、RL Query/Policy 四个 worker，通过 lock-free ring buffer 或共享时间戳交换状态。不要让 Diffusion 线程持有飞控关键锁，也不要把完整生成结果复制回 CPU 再给 RL；应在 GPU 上直接聚合必要的 $U_E$ / query 结果，只传少量状态。

### 16.7 退化运行模式

若 GPU 温度、功耗或负载过高，TESO-Diff 应按下列顺序退化：

1. $K = 4 \to 2$ 后验样本；
2. Diffusion 更新 1 Hz $\to$ 0.5 Hz；
3. query batch 减少，只评估 RL 当前候选；
4. 使用确定性 latent predictor $f_{\mathrm{det}}(C_{\mathrm{TESO}})$ 临时替代 Diffusion；
5. 若 TESO 失效，RL 只使用基础飞行状态并进入保守滑翔策略。

这种 graceful degradation 比要求生成模型始终在严格 deadline 内完成更符合安全机载系统设计。

## 17. 在线算法流程

### 17.1 在线观测器主循环

TESO-Diff 的在线主循环如算法 2。核心思想是把“高频证据更新”和“低频后验生成”分开，避免扩散模型阻塞控制。

**Algorithm 2** TESO-Diff 在线获能空间更新

**Require:** 历史缓存 $\mathcal{B}$，当前机载量测 $S_{\mathrm{raw}}(t)$，aircraft profile

时间同步并更新 GNSS/IMU/Pitot/姿态/$c_T$/飞控三维风估计
计算 $e_a(t)$、$p_{\mathrm{eng}}(t)$、$p_D(t)$ 的积分状态
将所有量按 $V_{\mathrm{ref}}$、$L_{\mathrm{ref}}$、$T_{\mathrm{ref}}$ 无量纲化
将新样本送入流式 DW-TCN 缓存
**if** 一个轨迹片段 $\tau_k$ 完成 **then**
    计算轨迹收益 $Y_{E,k}$ 与可信度 $q_{E,k}$
    输出 $h_{\tau,k}$ 并构造 token $z_k$
    将 $z_k$ 加入滑动历史 token 队列
**end if**
**if** 达到 History Encoder 更新周期 **then**
    计算 $c_{\mathrm{env}}, c_{\mathrm{local}}, c_{\mathrm{trend}}, c_{\mathrm{confidence}}$
    更新 $C_{\mathrm{TESO}}$ 与 OOD/证据质量评分
**end if**
**if** latent 过期或 $c_{\mathrm{trend}}$ 触发快速更新 **then**
    **for** $k = 1$ to $K$ **do**
        以 warm-start/noise 初始化 $Z_{E,T}^{(k)}$
        使用 2–4 步条件去噪得到 $Z_E^{(k)}$
    **end for**
    缓存 $K$ 个 Energy latent 样本及时间戳
**end if**
根据 RL 请求的候选 queries 批量运行 Energy Query Decoder
聚合 $\mu_E, \sigma_E, p_+, U_E, a_E^*$ 与 confidence
**return** RL Observation + latent age + OOD flags

### 17.2 轨迹能量在线积分

由于 $Y_E$ 使用时间段积分，不需要直接对噪声 $e_a(t)$ 做高频数值微分。维护三个累计量：

$$I_D(t) = \int p_D dt, \tag{81}$$

$$I_{\mathrm{eng}}(t) = \int p_{\mathrm{eng}} dt, \tag{82}$$

$$I_{\mathrm{ctrl}}(t) = \int p_{\mathrm{ctrl}} dt. \tag{83}$$

对任意 segment 起止点，只需读取环形缓存中的 $e_a$ 和三个累计积分差，即可得到式 (17)。这种做法比计算 $\dot{e}$ 对 GNSS 高度噪声和 Pitot 抖动更稳健。

### 17.3 Warm-start latent

若相邻两次 $C_{\mathrm{TESO}}$ 变化不大，可将上一时刻 latent 加适量噪声作为新扩散初值，而不是每次从纯高斯噪声开始。记旧 latent 为 $Z_E^{\mathrm{old}}$，可初始化

$$Z_{E,T_0} = \sqrt{\bar{\alpha}_{T_0}} Z_E^{\mathrm{old}} + \sqrt{1 - \bar{\alpha}_{T_0}} \epsilon, \tag{84}$$

其中 $T_0$ 选择较低噪声层级。这样能提升时间连续性并降低采样步数。但当 OOD 或 $c_{\mathrm{trend}}$ 突变时，应重新从高噪声初始化，避免旧信念锁死。

## 18. TESO-Diff 与强化学习接口

### 18.1 为什么不把完整 latent 直接交给 RL

若直接把 $16 \times 16 \times 8 \times 8$ latent 展平给 RL，状态维度仍然很高，而且 latent 语义随训练变化，不利于策略稳定。更合适的是由 State Builder 将其转换为少量、意义稳定的概率获能通道。

第一种接口是**局部低分辨率场**。在固定 $N_x^r \times N_y^r \times N_z^r$ 查询格点上，对每点优化或枚举小批候选 primitive，生成

$$O_E^{\mathrm{grid}} = \{U_E, \sigma_E, p_+, \boldsymbol{a}_E^*, q_{\mathrm{obs}}, \mathrm{age}\}. \tag{85}$$

例如空间只用 $12 \times 12 \times 6$，每个体素 6–8 通道，已经远低于高维风场输入。

第二种接口是**候选轨迹集合**。由 RL 或采样器提出 $N_a = 32 \sim 128$ 个候选短时机动，TESO 返回每个候选的

$$o_j = [\mu_E(q_j), \sigma_E(q_j), p_+(q_j), q_{\mathrm{obs}}, P_{\mathrm{unsafe}}(q_j)]. \tag{86}$$

RL 直接在这些候选上做选择或作为 actor 的辅助 feature。此接口计算最省，也最符合 “Energy Space 是动作条件函数” 的定义。

第三种接口是**热点摘要**。提取 top-$K$ 稳健高能区域的中心、尺度、置信度和推荐动作，仅用于极限算力或可视化。与旧方案 “圆柱/立方体” 不同，热点几何只是后处理摘要，不再假设真实环境一定是柱形热气流或立方风切变。

### 18.2 RL reward 与 TESO 输出必须分离

TESO 输出 $U_E$ 是环境可利用能量的观测，不应直接等同于 RL reward。RL 的总 reward 还可包括真实机械能变化、任务进度、安全、控制平滑和终端目标。若把 TESO 预测值直接作为主要训练奖励，策略可能利用模型偏差产生 “model exploitation”。更稳妥的用法是：TESO 作为 observation/critic feature，真实 simulator 能量变化仍作为 RL reward 的主要物理依据。

### 18.3 主动信息增益机动

当 $c_{\text{confidence}}$ 很低、但多个后验样本对某一区域给出截然不同的高价值预测时，可以定义信息价值

$$U_{\text{info}}(q) = \text{Var}_k[Y^q_{E,k}] \tag{87}$$

并让上层策略在 “纯获能” 和 “去验证一个可能高收益区域” 之间权衡。这给 TESO 一个自然的 active sensing 扩展：飞机不仅利用环境，也可以通过安全探测轨迹改善 Energy Space 后验。但第一阶段不建议把信息增益直接并入主 reward，应先作为独立研究项。

## 19. 详细算法结构与张量尺寸建议

### 19.1 推荐 MVP 配置

表 2 给出一组用于实现的起始配置。数值并非最终最优，而是基于 Jetson 轻量化目标给出的可操作初始点。

### 19.2 条件向量的进入位置

对每个 Diffusion residual block，时间 embedding 与 $c_g$ 先拼接，再通过小 MLP 产生 FiLM 参数。$c_{\text{confidence}}$ 还可额外控制 dropout 或 noise scale，使低证据条件下样本更分散。$c_{\text{local}}$ 不做全空间 token 拼接，而只在 bottleneck cross-attention 使用一次。这种结构应优先于 “每层 cross-attention + 大 Transformer”，因为本课题需要的是低延迟环境后验，而不是高语义文本生成。

### 19.3 连续 Query Decoder 的局部插值

Query 位置首先映射到 latent grid 归一坐标，使用三线性插值：

$$z_q = \sum_{i \in \mathcal{N}(r_q)} \omega_i(r_q) Z_{E,i}. \tag{88}$$

再拼接位置 Fourier features 可选项

$$\gamma(r_q) = [\sin(2^k \pi r_q), \cos(2^k \pi r_q)]_{k=0}^{K_f-1} \tag{89}$$

以增强细尺度边界表达。第一版 $K_f = 2 \sim 3$ 即可，避免过高频导致虚假振荡。MLP 输出可以是单个 $Y_E$，也可以额外输出 aleatoric log-variance；后验样本之间的方差表达 epistemic/多模态不确定性，两者不应混为一个数。

### 19.4 动作编码

连续 primitive 中的角度用正余弦表示，速度、转弯率和时间按物理尺度归一。动作编码器仅需一个小 MLP：

$$z_a = f_a([V^*_a, \sin\gamma, \cos\gamma, \dot{\chi}^*, \dot{\gamma}^*, c^q_T, T^*_q]). \tag{90}$$

Query Decoder 接收 $[z_q, z_a, c_{\text{aircraft}}, c_{\text{state}}]$。如果下游 RL 已经给出 future primitive，不必再由 TESO 预测控制动作；$a^*_E$ 只是通过批量 query 后的 argmax 派生量。

## 20. 不确定性、校准与 OOD 处理

### 20.1 两类不确定性

TESO-Diff 至少要区分：一是历史证据不足导致的后验不确定性，主要由多个 diffusion latent samples 的差异体现；二是同一环境下传感器与能量核算本身的 aleatoric 噪声，由 $q_E$、$q_W$ 与 Query Decoder 的可选方差头表达。总预测方差可近似

$$\sigma^2_{\text{total}} = \sigma^2_{\text{posterior}} + \sigma^2_{\text{aleatoric}}. \tag{91}$$

在历史完全缺失时，模型不应该输出某一张 “平均高能图”，而应接近训练先验且具有较大 $\sigma_{\text{posterior}}$。

表 2: TESO-Diff MVP 推荐张量与网络规模

| 模块 | 推荐尺寸 | 设计理由 |
|---|---|---|
| 统一采样状态 | 20 Hz，$d_x \approx 24 \sim 32$ | 高频 IMU 先做低通/统计，避免原始 200 Hz 进入网络 |
| 历史窗口 | $T_h = 20$ s | 能看到多段机动和短期趋势，内存低 |
| 轨迹片段 | $T_s = 3$ s，hop 1 s | 兼顾动态滑翔瞬态与短时热气流收益 |
| Trajectory Encoder | DW-TCN，32/48/64 channels，$h_\tau = 64$ | 并行、可流式、TensorRT 友好 |
| 历史 token | $N \le 24$，token dim 80–96 | 足以保留局部证据并控制注意力规模 |
| History Encoder | 2 层，model dim 96，4 heads | 只处理少量 token |
| $c_{\text{env}}$ | 96D | 全局 FiLM 条件 |
| $c_{\text{trend}}$ | 32D | 非定常变化摘要 |
| $c_{\text{confidence}}$ | 16D + 标量 $q_{\text{obs}}$ | 置信度与 OOD |
| $c_{\text{local}}$ | 12–16 tokens × 64D | 仅 bottleneck cross-attention |
| Energy latent grid | $16 \times 16 \times 8 \times 8$ | 比全风场/动作体素小数量级 |
| Diffusion U-Net | 两尺度, base 32, bottleneck 64 | 约 4–8M 参数预算 |
| 采样 | $K = 4$，2–4 denoise steps | 低频后验更新，保留风险样本 |
| Query Decoder | 3 层 MLP，hidden 128/128/64 | 连续动作/位置按需查询 |
| RL query batch | 32–128 | 依据 policy 频率与 GPU 负载动态选择 |

### 20.2 校准指标

必须同时报告：

- 50/80/90/95% 预测区间经验覆盖率；
- CRPS 或 NLL；
- $p_+$ 的 Brier score 与 reliability diagram；
- 风险调整后 $U_E$ 的保守性；
- 预测 top-$K$ 高收益 query 中真实正收益比例。

若 coverage 明显偏低, 可对 diffusion 样本做温度/方差膨胀或 conformal calibration。对于控制用途, “略保守但校准” 通常优于 “均值更准却过度自信”。

### 20.3 OOD 分数

OOD 可由三个轻量来源组成：history embedding 到训练簇的 Mahalanobis 距离、输入物理变量超出训练范围的规则检查、以及 ensemble/latent disagreement。组合得到

$$q_{\text{ood}} = \sigma\left(w_1 d_{\text{emb}} + w_2 d_{\text{range}} + w_3 d_{\text{disagree}} + b\right). \tag{92}$$

当 $q_{\text{ood}}$ 高时，State Builder 增大 $\beta$、限制最大推荐机动强度，并可通知 RL 进入保守模式，而不是让生成网络在未知分布上 “编造” 高收益空间。

## 21. 验证指标与基线

### 21.1 基线体系

为了证明 TESO-Diff 的价值，至少需要以下基线：

1. B0：无 Energy Space，只给 RL 当前机械能与基础飞行状态；
2. B1：最近轨迹 $Y_E$ 的空间时间衰减外推；

3. B2：局部 Gaussian Process/Kriging，以轨迹位置和 $Y_E$ 回归标量收益；
4. B3：单层 GRU 历史编码 + deterministic query decoder；
5. B4：DW-TCN + deterministic Energy latent predictor；
6. B5：DW-TCN + variational Gaussian latent；
7. B6：完整 TESO-Diff；
8. B7：完整模型去掉 $\hat{W}_{\mathrm{FC}}$；
9. B8：去掉 $c_{\mathrm{trend}}$；
10. B9：去掉 $c_{\mathrm{confidence}}$；
11. B10：不用 aircraft normalization/token；
12. B11：发动机能量不扣除或不输入 $c_T$ 的错误对照。

尤其 B11 很重要，它可以直接证明有动力训练数据若不做推进能量分离，会造成环境获能观测的系统性污染。

### 21.2 分层指标

表 3 给出从标签到 RL 的分层指标。

### 21.3 核心成功判据

在获得具体平台参数前，数值门槛应作为待冻结目标。本文建议先设研究性门槛：

- G1：无风/有风、无动力/有动力四类能量核算单元测试全部通过，$Y_E$ 不随发动机系数产生伪环境收益；
- G2：TESO deterministic baseline 对反事实 query 的排序显著优于“最近 $Y_E$ 外推”；
- G3：完整 Diffusion 的 CRPS/NLL 相对 deterministic/单 Gaussian latent 有明显改善，同时均值误差不显著恶化；
- G4：留出机型上，经物理无量纲化后的性能下降可控，且显著优于仅全局 z-score；
- G5：$p_+$ 和 90% 区间具有可接受校准，未观测区域不会普遍高置信；
- G6：在 Jetson Orin Nano 与目标 RL policy 同时运行时，TESO 的高频 Query 不阻塞控制，低频 Diffusion 可异步完成；
- G7：加入 TESO observation 的 RL 在相同环境和安全约束下提高净环境获能、航时或降低发动机能耗，而不是仅提高预测离线指标。

## 22. 主要风险与抑制措施

### 22.1 历史轨迹不足以唯一确定未观测 Energy Space

这是根本不可辨识性，而不是网络规模问题。同一条正获能轨迹可能由热气流、剪切、非定常 gust 或多种混合环境造成。TESO-Diff 通过多个后验样本表达这种歧义；若用户要求一张确定地图，模型反而会把多个假设平均成物理上并不存在的模糊结构。评估时必须保留“先验主导区、证据约束区、OOD 区”的区别。

### 22.2 轨迹级标签过长导致空间定位模糊

如果 $T_s$ 太长，一段 $Y_E$ 可能跨越多个环境结构，导致模型难以知道收益来自哪里。解决方法是重叠多尺度片段，并在 token 中保留轨迹几何与中点/路径位置，而不是只存 segment 起点。训练 query 一致性时可把观察轨迹 primitive 作为整段输入，使 decoder 学习路径依赖。

### 22.3 推进能量分离错误

有动力飞机中，发动机模型是最容易产生伪获能的来源。需要在无风环境下扫描 $c_T \in [0,1]$ 做系统测试；若扣除后 $Y_E$ 仍随油门单调变化，必须重新辨识 $a_{\mathrm{eng}}$。真实飞行可用不同油门水平的稳态直飞、加速段建立推进校准表。模型输入应保留 $q_T$，低可信度推进段降低 $Y_E$ 监督权重。

### 22.4 飞控三维风估计偏差

虽然 TESO 不依赖完整风场，但 $\hat{W}_{\mathrm{FC}}$ 仍可能成为网络的“捷径”。训练必须对风估计通道做 bias、delay、dropout 随机化，并报告“有/无 wind estimate”消融。如果去掉该通道性能完全崩溃，说明模型仍然过度依赖风估计而未真正利用 trajectory-energy 证据。

表 3: TESO-Diff 分层验证指标

| 层级 | 指标 | 目的 |
|---|---|---|
| 能量核算 | $Y_E$ 与 simulator direct work 的 MAE/bias；有动力/无动力分别报告 | 验证发动机扣除、阻力补偿与符号正确 |
| 轨迹编码 | future local $Y_E$ 预测、风估计辅助误差、机动类别线性 probe | 检查 $h_\tau$ 是否保留有用交互信息 |
| Energy query | $Y_E$ MAE/Huber、Spearman 排序、top-$K$ regret、正收益 AUROC | 检查是否支持动作选择 |
| 空间结构 | 高收益区 precision/recall、热点位置误差、不同 horizon 一致性 | 检查未观测区域外推 |
| 不确定性 | CRPS/NLL、coverage、Brier、OOD AUROC | 防止未观测区过度自信 |
| 跨机型 | leave-one-aircraft-out 性能下降、归一化消融 | 验证尺度泛化 |
| 实时性 | Encoder/History/Diffusion/Query latency、峰值显存、GPU 占用、RL 共存延迟 | 验证 Orin Nano 部署 |
| 下游 RL | 总航时、净环境能量、发动机能耗、失速/超载率、任务完成率 | 验证 TESO 是否真正改善自主获能滑翔 |

### 22.5 Energy latent 学成 simulator-specific 表征

如果所有数据来自一类解析热气流，latent 很可能只学会特定几何模板。必须通过混合机制、不同机型、不同控制策略和隐藏场实现多样性；最好使用多种 simulator fidelity，并把高保真/真实数据作为留出验证。Energy Query 的最终性能比 latent 可视化更重要。

### 22.6 Diffusion 样本多样但不校准

生成多个不同场并不自动等于不确定性正确。需要用 coverage、CRPS、Brier 做严格校准；必要时对样本做温度缩放、方差膨胀或后验 reweight。不能用“看起来样本很多样”代替概率验证。

### 22.7 扩散对机载算力仍过重

采用 latent grid、两尺度 U-Net、深度可分离卷积、4 步以内采样、异步更新和 deterministic fallback。若仍达不到目标，应先降低 $K$ 和更新频率，而不是缩短 RL 控制频率。最终也可以将训练好的 Diffusion 蒸馏为 one/few-step consistency student，但必须重新校准不确定性。

### 22.8 RL 利用观测器误差

策略可能学会寻找 TESO 系统性高估区域。训练 RL 时应加入 TESO noise/randomization，使用真实 simulator energy 作为 reward，且在测试中加入 model-error adversarial cases。高 $U_E$ 只作为状态，不应无条件成为奖励真值。

## 23. 消融实验矩阵

建议至少完成以下消融：

1. 逐点 $\dot{e}$ 标签 vs. 3 s 轨迹 $Y_E$ vs. 多尺度 $Y_E$；
2. 无动力数据 vs. 有动力且正确扣除推进 vs. 有动力不扣除推进；
3. 原始物理量 z-score vs. $V_{\mathrm{ref}}$ 物理无量纲化；

4. 无 aircraft token vs. 8D/16D aircraft token；
5. 无飞控三维风估计 vs. 有风估计 vs. 风估计随机 dropout；
6. GRU、LSTM、DW-TCN、Neural CDE trajectory encoder；
7. pooling history vs. 小 GRU vs. 2-layer causal attention；
8. 仅 $c_{\text{env}}$ vs. 加 $c_{\text{local}}$ vs. 完整四元 $C_{\text{TESO}}$；
9. deterministic latent、Gaussian VAE latent、TESO-Diff;
10. full 3D convolution vs. depthwise-separable 3D U-Net；
11. 20/10/4/2 diffusion steps 与 consistency student；
12. $12 \times 12 \times 6$、$16 \times 16 \times 8$ latent grid；
13. 离散动作体素 vs. continuous Query Decoder；
14. 固定 Diffusion 1 Hz vs. trend-triggered adaptive update；
15. Gymnasium 解析数据-only vs. 加 NVIDIA/Warp 高吞吐随机化数据 vs. 加真实飞行适配。

每个消融都要同时报告离线 energy-query 指标、不确定性、Jetson latency 和下游 RL 指标，避免只用一个 MAE 得出架构结论。

## 24. 研究实施路线与工作包

### 24.1 优先级说明

WP0、WP1、WP2 必须先于 Diffusion。若 $Y_E$ 在有动力情况下没有正确扣除推进，或 Query Decoder 不能从理想 latent 表达能量空间，直接训练生成模型没有意义。WP3 先证明历史轨迹确实含有对未观测获能空间有用的信息。WP4 才回答“多模态后验是否比确定性外推更好”。WP6 之前不要过早优化单个 CUDA kernel；先冻结模型输入输出和验证指标，再做 TensorRT/量化。

## 25. 与原 WFEF 能量物理的关系

### 25.1 WFEF 不再是部署必需，但仍是重要教师

TESO-Diff 并不是否认风场物理。真实环境能量最终仍来自垂直风、风切变和非定常风。原 WFEF-Diff 中严格的环境比功率

$$P_W = gW_z - \boldsymbol{v}_a^T \left(\partial_t \boldsymbol{W} + J_W \boldsymbol{v}_g\right) \tag{93}$$

仍可在仿真真值已知时计算，并作为 $Y_E$ direct teacher：

$$Y_E^{\text{WFEF}} = \int_t^{t+T_s} P_W \, dt. \tag{94}$$

训练数据生成阶段可以比较 $Y_E^{\text{WFEF}}$、simulator force work 与式 (17) 的机载可观测核算结果。三者一致性是非常强的验证手段。

区别只在部署目标：WFEF-Diff 要求在线先得到 $W$ 和导数；TESO-Diff 允许网络把风场作为潜在成因，通过历史 trajectory-energy evidence 直接推断 $\mathcal{E}$。因此 WFEF 更像“物理教师/仿真真值接口”，TESO 是“机载任务观测器”。

### 25.2 为什么保留飞控风估计仍然合理

如果飞控已经能以很低额外成本输出局部三维风预估，完全丢弃它也没有必要。TESO 的原则不是“绝对不用风”，而是“不把恢复完整非定常风场作为获能空间成立的必要前提”。局部风估计提供额外辨识信息，特别是区分热气流、侧风和剪切穿越；轨迹 $Y_E$ 则提供“这个环境结构对当前飞机到底是否有用”的直接证据。二者结合比任一单独使用更合理。

## 26. 推荐的 TESO-Diff 输出协议

每次 History/Diffusion 更新建议发布

$$O_t^{\text{TESO}} = \{C_{\text{TESO}}, \bar{Z}_E, \Sigma_{Z_E}, q_{\text{obs}}, q_{\text{ood}}, t_{\text{stamp}}, t_{\text{age}}\}, \tag{95}$$

该内部协议供 Query Server 使用。对 RL 发布的外部接口不必包含 latent，而是根据模式选择：

$$O_t^{\text{RL}} = \{U_E, \sigma_E, p_+, a_E^*, q_{\text{obs}}, q_{\text{ood}}, t_{\text{age}}\}. \tag{96}$$

若使用候选动作接口，则发布 $\{q_j, \mu_j, \sigma_j, p_{+,j}, P_{\text{unsafe,j}}\}_{j=1}^{N_q}$。所有输出必须带时间戳与 age，因为在快速非定常环境中“一张 5 秒前的好地图”可能比当前低分辨率观测更危险。

表 4: TESO-Diff 建议工作包

| 工作包 | 目标 | 主要交付物 | 退出条件 |
|---|---|---|---|
| WP0 | 能量核算与推进分离 | $Y_E$ 统一脚本、发动机 $V_{\mathrm{TAS}}a_{\mathrm{eng}}$ 模型、单元测试 | 有/无动力无风测试无伪环境收益 |
| WP1 | Gymnasium 数据生成器 | 6-DOF、风能场、传感器/风估计模拟、反事实 rollout | 可稳定批量生成 $(\mathcal{H}, \mathcal{Q}^{gt})$ |
| WP2 | Energy latent / Query Decoder | continuous action query、AE 与排序损失 | 反事实能量与动作排序达到基线目标 |
| WP3 | 轻量 TESO Encoder | DW-TCN、四元 $C_{\mathrm{TESO}}$、aircraft normalization | 跨机型历史预测优于 GRU/最近值基线 |
| WP4 | Conditional Diffusion | 两尺度 3D latent diffusion、$K$ 样本、校准 | CRPS/NLL 优于 deterministic/Gaussian latent |
| WP5 | NVIDIA/Warp 高吞吐与域随机化 | GPU 并行 6-DOF、counterfactual kernel、数据扩充 | 数据量与分布覆盖满足训练需求 |
| WP6 | Jetson 机载化 | TensorRT、流式缓存、少步蒸馏、异步调度 | 与 RL 同跑满足延迟/显存/功耗门槛 |
| WP7 | RL 与飞行验证 | TESO observation 接口、仿真 RL、半实物/实飞 | 航时/净环境获能/发动机能耗有显著收益 |

## 27. 设计建议与阶段性结论

TESO-Diff 的研究价值来自目标重构，而不是简单把原风场 Diffusion 的输入换成另一组数据。它把自主获能滑翔的核心问题从“尽可能完整地知道空气怎么流”改为“根据飞机刚才实际怎么飞、赚了多少能量，形成对附近可利用能量的概率信念”。这种表述承认单机观测不可辨识性，但不要求为了解决控制问题先完成一个更难的全风场反演问题。

在这一架构中，轨迹编码器负责将不同机型、不同量纲和不同采样率的历史转化成稳定的获能经验；$C_{\mathrm{TESO}}$ 的四元结构把总体信念、局部证据、时间趋势和可信度分开；飞控三维风估计作为有价值但可缺失的辅助证据；有动力飞机通过 $c_T$ 和 $V_{\mathrm{TAS}}a_{\mathrm{eng}}$ 明确扣除发动机能量；条件潜扩散只在低分辨率 Energy latent 上表达多个可能后验；连续 Query Decoder 让 RL 按实际候选轨迹查询累计环境收益。整个链路围绕“获能滑翔”而不是“流场可视化”优化。

对于 Jetson Orin Nano，最重要的不是把一个大型 4D 网络硬塞进边缘 GPU，而是通过架构分工降低必须实时计算的内容：20 Hz 只更新积分与轻量 TCN；1–2 Hz 更新历史条件；0.5–1 Hz 做少步 Diffusion；RL 高频只访问缓存 latent 和小型 MLP。若生成模型暂时不可用，还可以退化到 deterministic latent predictor，而不影响基础控制。这样的系统更符合真实机载自主获能任务的资源结构。

最后，TESO-Diff 的三项关键证伪实验应是：第一，在完全不输入地形、只给历史飞行经历与飞控局部风估计时，能否对未飞区域的反事实轨迹收益给出优于简单外推的排序；第二，在有动力与无动力混合数据中，推进分离后模型是否真正学习环境能量而非油门；第三，在目标 Jetson Orin Nano 与 RL 同时运行时，多样本少步后验是否仍能带来比确定性 Energy Space 更好的下游航时或净能量表现。只有这三项同时成立，才说明 TESO-Diff 的生成式复杂度具有工程价值。

## A. 符号与数据字段建议

推荐每个原始时刻记录字段：时间戳、ENU 位置、GNSS 地速、真空速、姿态四元数/欧拉角、机体角速度、IMU 比力、载荷因子、飞控三维风估计

表 5: TESO-Diff 主要符号

| 符号 | 含义 | 备注 |
|---|---|---|
| $V_{\mathrm{TAS}}$ | 真空速 | 前向 Pitot 经飞控补偿后的空速标量 |
| $c_T$ | 发动机功率系数 | $[0,1]$，0 为无动力/关机 |
| $a_{\mathrm{eng}}$ | 推进贡献前向加速度 | 不使用未经分离的原始 IMU $a_x$ |
| $p_{\mathrm{eng}}$ | 发动机单位质量比功率 | $V_{\mathrm{TAS}}a_{\mathrm{eng}}$ |
| $Y_E$ | 轨迹累计环境能量收益 | Eq. (17)，单位 J/kg |
| $\hat{W}_{\mathrm{FC}}$ | 飞控三维局部风估计 | 辅助输入，不是完整风场真值 |
| $h_\tau$ | 单轨迹片段编码 | DW-TCN/GRU/CDE 输出 |
| $c_{\mathrm{env}}$ | 整体获能环境信念 | Diffusion 全局条件 |
| $c_{\mathrm{local}}$ | 局部 trajectory-energy tokens | bottleneck cross-attention |
| $c_{\mathrm{trend}}$ | 历史证据变化趋势 | 用于非定常性 |
| $c_{\mathrm{confidence}}$ | 证据质量/充分性 | 控制保守性与 OOD |
| $Z_E$ | Energy Affordance latent grid | Diffusion 生成对象 |
| $q$ | Energy Query | 位置、未来时间、状态、primitive、horizon |
| $U_E$ | 稳健获能潜力 | 风险调整后的候选动作最大收益 |

及协方差/健康度、$c_T$、推进估计加速度、舵面/高层控制命令、传感器健康度。每个 segment 记录起止索引、相对路径坐标、$\Delta e_a$、$\int p_D dt$、$\int p_{\mathrm{eng}} dt$、$Y_E$、$\sigma_E$、TCN embedding。每个训练锚点记录 history token、aircraft token、counterfactual queries、隐藏环境 seed、simulator direct work 与数据版本。

## B. 推进能量核算的离散实现

令采样间隔 $\Delta t$，使用梯形积分

$$I_{\mathrm{eng},n+1} = I_{\mathrm{eng},n} + \frac{\Delta t}{2}(p_{\mathrm{eng},n} + p_{\mathrm{eng},n+1}), \quad (97)$$

$$I_{D,n+1} = I_{D,n} + \frac{\Delta t}{2}(p_{D,n} + p_{D,n+1}). \quad (98)$$

片段 $[i,j]$ 的环境收益

$$Y_E = (e_{a,j} - e_{a,i}) + (I_{D,j} - I_{D,i}) + (I_{\mathrm{ctrl},j} - I_{\mathrm{ctrl},i}) - (I_{\mathrm{eng},j} - I_{\mathrm{eng},i}). \quad (99)$$

真空速应在能量计算前低通，但滤波延迟必须与 GNSS 高度/速度时间对齐。若 $V^2$ 先平方再低通与先低通再平方会产生轻微偏差，应在仿真与部署使用相同处理顺序。

**Algorithm 3** 轨迹级 $Y_E$ 在线计算

**Require:** $V_{\mathrm{TAS}}, z, c_T, a_{\mathrm{eng,max}}$, 气动参数, 环形缓存

$e_a \leftarrow 0.5V_{\mathrm{TAS}}^2 + gz$

$a_{\mathrm{eng}} \leftarrow c_T a_{\mathrm{eng,max}}(V_{\mathrm{TAS}}, h)$ 或飞控推进估计

$p_{\mathrm{eng}} \leftarrow V_{\mathrm{TAS}} a_{\mathrm{eng}}$

由极曲线/校正器计算 $p_D$ 与 $p_{\mathrm{ctrl}}$

梯形积分更新 $I_D, I_{\mathrm{ctrl}}, I_{\mathrm{eng}}$

**if** segment $[i,j]$ 完成 **then**

  $Y_E \leftarrow (e_j - e_i) + (I_{D,j} - I_{D,i}) + (I_{\mathrm{ctrl,j}} - I_{\mathrm{ctrl,i}}) - (I_{\mathrm{eng},j} - I_{\mathrm{eng},i})$

  传播/估计 $\sigma_E$，得到 $q_E$

  输出 $(Y_E, q_E)$

**end if**

## C. TESO-Diff 训练伪代码

**Algorithm 4** TESO-Diff 分阶段训练

**Require:** 数据集 $\{(\mathcal{H}_t, \mathcal{Q}_t^{gt}, A_t)\}$

**Stage 0:** 运行所有能量与发动机分离单元测试
**Stage 1:** 训练 Energy Autoencoder / Query Decoder
**for** batch of counterfactual query sets **do**
    $Z_E^{gt} \leftarrow E_\psi$(hidden environment/query set)
    最小化 $\mathcal{L}_{query} + \lambda_r \mathcal{L}_{rank} + \lambda_s \mathcal{L}_{spatial}$
**end for**
冻结或慢更新 Query Decoder
**Stage 2:** 训练 DW-TCN + History Encoder
**for** batch of histories **do**
    分段、无量纲化，计算 $h_{\tau,k}$ 与 tokens $z_k$
    形成 $C_{TESO}$，训练 deterministic latent / future-energy auxiliary heads
**end for**
**Stage 3:** 训练 conditional latent diffusion
**for** batch **do**
    从 $Z_E^{gt}$ 随机采样 diffusion timestep 与噪声
    $\epsilon_\theta \leftarrow \text{UNet3D}(Z_{E,\tau}, \tau, C_{TESO})$
    最小化 $\mathcal{L}_{diff} + \lambda_o \mathcal{L}_{obs} + \lambda_c \mathcal{L}_{conf}$
**end for**
**Stage 4:** conditional dropout、OOD、跨机型与真实数据适配
**Stage 5:** consistency/DDIM 少步蒸馏并重新校准
**return** Jetson student encoder + latent generator + query decoder

## D. 建议的软件模块边界

为方便代码落地，建议仓库拆成：

1. `teso/energy/`：$e_a$、$p_D$、$p_{eng}$、$Y_E$、不确定性与单元测试；
2. `teso/normalization/`：aircraft profile、$V_{ref}$ 与所有无量纲化；
3. `teso/encoder/`：streaming DW-TCN、history encoder、四元条件头；
4. `teso/energy_field/`：latent encoder、query decoder、counterfactual dataset；
5. `teso/diffusion/`：2-scale 3D U-Net、sampler、distillation；
6. `teso/sim/gymnasium/`：快速 6-DOF 环境与解析风能场；
7. `teso/sim/nvidia/`：Isaac Lab/Warp GPU environment；
8. `teso/deploy/`：ONNX/TensorRT、ring buffer、CUDA stream、ROS2/飞控接口；
9. `teso/rl_interface/`：grid query、candidate query、State Builder；
10. `teso/eval/`：energy、calibration、OOD、latency 与 RL 指标。

这种边界使能量核算可以在没有任何深度学习代码时独立测试，也使模拟器、TESO 和 RL 可以各自升级而不互相耦合。

## E. 进一步可扩展研究方向

### E.1 连续时间编码

若真实飞行出现大量异步采样和丢包，可将 DW-TCN teacher 替换或补充为 Neural CDE；再蒸馏到固定步长 TCN。研究重点应放在“异步处理是否显著提升 energy-query 泛化”，而不是追求数学形式复杂。

### E.2 自监督轨迹预训练

大量真实飞行日志可能没有可靠 $Y_E$ 或反事实标签，但仍可用于自监督预训练 TCN，例如 masked segment reconstruction、下一段状态对比预测、不同采样率一致性。预训练后再用仿真/少量标注数据微调 Energy Encoder，有望提高真实域泛化。

### E.3 联合信息价值与获能价值

未来可扩展 Query Decoder 同时输出 $Y_E$ 与预计后验信息增益，让 RL 在环境不确定时选择探索机动。但需要防止策略为“看清环境”而消耗过多能量，适合采用 constrained multi-objective 而非简单加权。

### E.4 可选地形上下文

本文第一阶段不输入地形。若后续山地飞行实验证明 history-only TESO 对背风转子、山脊上升流等结构的外推严重不足，可以增加一个非常低维的 terrain context，例如当前点到局部山脊方向/高度差的摘要，而不是重新输入大 SDF 体素。这样仍保留“能量直接观测为主、地形只作弱先验”的设计哲学。

### E.5 与 WFEF 双头教师模型

离线高保真训练可以建立共享环境 encoder，一头预测 $Z_E$，另一头预测局部 $W$ 或 WFEF 物理量；部署时裁剪风场头。多任务训练可能迫使 latent 保留更多物理一致结构，同时避免机载端承担完整风场输出成本。该方向应通过消融验证，不应默认多任务一定更好。

## F. 设计选择的进一步说明：从“轨迹证据”到“空间信念”

### F.1 TESO 的观测对象不是单一能量值

在工程实现中最容易出现的误解，是把 TESO 简化成“输入最近几十秒状态，输出一个当前获能分数”。这种做法虽然容易训练，却没有解决空间观测问题。TESO 的历史编码器真正要抽取的是**环境在轨迹交互下留下的结构化证据**。一段轨迹的 $Y_E$ 只给出整体收益，而轨迹内部的速度变化、位置变化、姿态变化、飞控风估计和推进干预共同决定这条证据应被怎样解释。例如，连续盘旋中多个相邻片段都获得正 $Y_E$，且飞控风估计的垂直分量持续为正，这种证据更支持“附近存在持续上升结构”；而高速下降后转弯拉起的一组片段呈现正负收益交替，则更可能支持“某个方向上的能量交换机制”。TESO 不必显式给这些机制命名，但 $h_\tau$ 和 $c_{\text{local}}$ 必须保留足够信息，使后面的生成模型可以区分这些交互模式。

因此，训练时不建议只用 $Y_E$ 监督轨迹编码器。除了第 10 节提出的局部风辅助头，还可以加入轨迹状态重构的弱辅助任务，例如预测片段的总位移、平均空速、平均转弯率、最大载荷因子与 $c_T$ 统计。这些任务的目的不是让模型精确复制输入，而是防止 $h_\tau$ 退化成“只记住最后一个 $Y_E$ 的标量编码”。辅助头在部署时全部裁剪，对 Jetson 没有额外开销。

### F.2 为什么四元条件优于单个 VAE latent

直接把历史序列编码成一个 Gaussian latent $z \sim \mathcal{N}(\mu, \sigma)$ 是一个合理基线，但它会把四种性质不同的不确定信息混合在一起：环境总体类型、与某一空间位置相关的局部证据、非定常变化趋势，以及“我到底看得够不够”的证据质量。如果所有信息只通过一个 128 维向量进入 Diffusion，生成网络难以判断某个 latent 维度的变化究竟意味着环境正在移动，还是传感器变差。

四元 $C_{\text{TESO}}$ 的价值就在于做**结构化瓶颈**。$c_{\text{env}}$ 可以比较平滑地表示整体模式；$c_{\text{local}}$ 保留离散历史 token，允许空间位置与历史证据做显式对应；$c_{\text{trend}}$ 强化时间非平稳信息；$c_{\text{confidence}}$ 则直接告诉生成器哪些条件应被信任。即使四个分支内部仍然是神经网络 learned feature，这种职责划分也能让损失函数和消融实验更加清楚。例如可以单独破坏历史时间顺序观察 $c_{\text{trend}}$ 是否失效，或人工降低 $q_E$ 观察 $c_{\text{confidence}}$ 是否使后验变宽。

### F.3 为什么 Diffusion 不是第一步就必须使用

TESO 的科学问题应按难度递增。首先要证明存在函数

$$f : \mathcal{H}_t \mapsto \hat{\mathcal{E}} \tag{100}$$

能从历史轨迹得到有用的 deterministic Energy Space。如果连确定性预测都无法比简单时空外推更好，则说明历史观测、轨迹 primitive 或 $Y_E$ 定义中仍有信息缺失，此时加入 Diffusion 只会把同样的错误变成多个随机样本。只有在 deterministic predictor 已经能抓住平均结构，但面对稀疏历史时出现“两个或多个合理空间假设被平均”的现象，Diffusion 才真正解决一个独立问题：表示非高斯、多模态的条件后验。

VAE 可以作为中间基线。Gaussian VAE 假设单个连续近似后验，计算量比 Diffusion 低，若测试表明 Energy Space 的主要不确定性近似单峰，VAE 甚至可能成为更好的机载选择。TESO-Diff 因此不是预设“扩散一定优于 VAE”，而是把 Diffusion 作为当后验多模态被实验确认后的主模型。研究报告

应同时保留 deterministic、VAE 与 Diffusion 三条线，避免为了使用生成模型而使用生成模型。

### F.4 轨迹 primitive 的“可执行性”必须由低层模型保证

Energy Query 不是任意数学曲线。若 Query Decoder 训练时大量接收真实飞机根本无法执行的高曲率、高过载、高爬升角轨迹，它可能在这些区域预测很高收益，而 RL 也可能被误导。训练数据生成器因此必须在 rollout 前经过 feasibility filter。可以用最小转弯半径、失速速度、最大过载、滚转率和最大推进/爬升能力构造近似集合 $\mathcal{A}(s)$；高保真阶段再由内环控制器真正跟踪 primitive，若跟踪误差过大则把 query 标为不可执行。

这种“动作可执行性”也是 aircraft token 的重要作用。同一个目标转弯率对轻型滑翔机和重型平台可能对应完全不同的过载与阻力，因此 Query Decoder 必须同时看到无量纲动作与 aircraft token。通过这种方式，Energy Space 表示的是“对当前飞机可利用的环境能量”，而不是脱离航空器动力学的抽象空气能量密度。

### F.5 有动力数据为何不是对纯滑翔目标的污染

自主获能滑翔的终极目标可能希望尽量少用发动机，但实际无人机往往需要发动机完成起飞、脱离危险、重新定位或维持最低安全高度。完全丢弃有动力轨迹会浪费大量真实数据，也会使模型在发动机开启时突然失去环境观测能力。通过式 (12) 和式 (17)，TESO 可以把推进做功从机械能变化中分离，因此有动力轨迹仍能贡献环境证据。

$c_T$ 的另一个作用是帮助编码器识别“主动激励”。例如在弱风区轻微改变推进可以改变飞机的空速和轨迹，从而让飞控风估计和能量响应提供额外辨识信息。TESO 不要求主动使用发动机探测环境，但在历史中发生这种行为时，模型应知道能量变化的一部分来自推进，而不是把它当作环境高能区。将 $c_T$ 与 $p^*_{\text{eng}}$ 同时输入比只在标签端扣除推进更稳健，因为编码器可以理解该片段的运动模式受到发动机干预。

### F.6 飞控三维风估计应如何进入四元条件

飞控风估计最适合进入 $c_{\text{local}}$ 与 $c_{\text{trend}}$，而不是直接拼成一个空间网格。单个 trajectory token 可以保留片段平均 $\bar{W}^*_x, \bar{W}^*_y, \bar{W}^*_z$、变化量以及质量 $q_W$；History Encoder 再从多个片段学习风估计与 $Y_E$ 的关系。这样，若某一局部风估计出现短时异常，$q_W$ 和其他轨迹证据可以降低它的影响；如果风估计长期一致，模型又能利用这一额外信息提高未观测区域辨识。

训练中应专门构造“风估计正确但 $Y_E$ 很小”“风估计偏差很大但轨迹收益可靠”“风估计暂时缺失”三类场景。若模型在这些情况下仍能保持合理校准，才能说明它把风估计当成证据而非真值捷径。

### F.7 为什么不输入地形仍可形成合理研究闭环

地形确实能改变局部边界层、山脊上升流和分离结构，但“地形与获能潜力的关系”并不是直接观测关系，而是通过空气动力环境间接作用。TESO 第一阶段排除地形，可以把研究问题收缩成一个更可证伪的命题：仅依赖航空器自己的轨迹交互和飞控估计，能否从稀疏历史中推断比局部外推更有价值的 Energy Space？如果答案是否定的，再加入地形也许只是让网络依靠强先验记忆常见风型，无法证明 trajectory-energy observer 本身有效。

另一方面，不输入地形并不意味着飞行安全忽略地形。碰撞、最低离地高度等约束应继续由导航/安全模块处理；TESO 只负责环境能量 affordance。这样的模块边界也减少了 TESO latent 的空间尺度负担。未来如果需要山地增强，可以输入极低维地形摘要并独立做消融，而不改变主架构。

## G. 面向获能滑翔任务的典型工作示例

### G.1 示例一：热气流搜索与进入

假设无人机最近 20 s 中先直线滑翔，随后在某一区域出现连续三个正 $Y_E$ 片段，并且飞控三维风估计显示 $W_z$ 增大。Trajectory Encoder 将直线进入、开始转弯、持续盘旋的运动模式分别编码；$c_{\text{local}}$ 保留各片段的相对空间位置；$c_{\text{trend}}$ 判断正收益是在增强还是减弱；$c_{\text{confidence}}$ 根据多条一致证据提高可信度。Diffusion 可能生成若干不同的 Energy latent：

有的样本认为热气流中心位于左前方，有的认为位于正前方，但它们都在已观测轨迹附近保持较高一致性。

RL 查询若干“继续左转盘旋”“右转扩大半径”“直飞穿出”等 primitives，Query Decoder 给出各自未来 3–6 s 的 $Y_E$ 分布。RL 不需要知道热气流是否严格为圆柱，也不需要读 $W_z$ 地图；它只看到继续某种盘旋在多个后验样本中有较高正收益概率，而直飞离开风险较大。随着新轨迹到达，$c_{\text{local}}$ 和 $c_{\text{trend}}$ 更新，热点中心可以自然移动，而不依赖固定热气流几何模型。

### G.2 示例二：动态滑翔剪切穿越

飞机下降加速接近剪切层时，某些片段 $Y_E$ 可能为负，因为势能正在转化且阻力存在；穿越后转向与拉升的后续片段使完整循环累计 $Y_E$ 为正。如果模型使用逐点正收益标签，前半段会被错误视为应避开的区域。TESO 使用重叠 3 s 片段与多尺度收益后，可以观察到“特定方向的速度/转弯轨迹组合”与后续正收益相关。

$c_{\text{trend}}$ 在这种情况下尤其重要，因为剪切结构相对飞机的方向与距离变化快。Diffusion 输出的 Energy Space 也不会简单标记“剪切层本身是高能体素”，而是对不同穿越方向给出不同 $Y_E(q)$。这使 RL 可以学习完整的动态滑翔循环，而不是只追逐瞬时能量增加。

### G.3 示例三：有动力重新定位后的关机获能

有动力飞机先以 $c_T = 0.5$ 爬升或横向重新定位。机械能明显增加，但式 (17) 扣除了 $p_{\text{eng}}$，因此如果环境没有贡献，$Y_E$ 仍接近零。随后飞机关机进入上升气流，$c_T = 0$ 且 $Y_E > 0$，模型才将该区域作为环境获能证据。若推进校准不准确，$q_T$ 降低会同步降低相关片段 $q_E$，避免这段数据强行约束 Diffusion。

这一示例说明 TESO 的“获能空间”不是“哪里能让总机械能增加”，而是“哪里能让环境对飞行器提供正净能量”。这一区分对评估发动机节能效果非常关键：RL 后续可以在任务完成率相同的条件下比较发动机能耗是否下降，而不是因为开更多油门而获得更高总能量。

### G.4 示例四：证据冲突与高不确定性

飞机在同一邻域先后两次经过，一次得到显著正 $Y_E$，另一次得到接近零甚至负收益；飞控风估计也显示快速变化。确定性模型容易平均为“中等收益”，但真实环境可能是一个正在漂移的热泡，也可能是短时 gust。TESO 的 $c_{\text{trend}}$ 表达变化，$c_{\text{confidence}}$ 识别证据冲突，Diffusion 保留多个可能 latent。最终 $\mu_E$ 可能中等，但 $\sigma_E$ 很大，使 $U_E = \mu_E - \beta\sigma_E$ 自动降低。

此时 RL 可以选择保守绕开，也可以在安全裕度足够时执行信息增益机动。模型不需要强行回答“真实风场到底是哪一种”，但能够诚实表达“这里可能有能量，可是当前证据不足”。这正是概率 Energy Space 相对于确定风场均值或单点能量图的主要控制价值。

## H. 参考文献与在线资源

## 参考文献


[1] J. W. Langelaan, J. Spletzer, C. Montella, and J. Grenestedt, “Wind field estimation for autonomous dynamic soaring,” *IEEE ICRA*, 2012, pp. 16–22. doi:10.1109/ICRA.2012.6224954.

[2] F. Achermann et al., “WindSeer: real-time volumetric wind prediction over complex terrain aboard a small uncrewed aerial vehicle,” *Nature Communications*, vol. 15, art. 3507, 2024. doi:10.1038/s41467-024-47778-4.

[3] F. Rozet and G. Louppe, “Score-based data assimilation,” *NeurIPS*, vol. 36, 2023.

[4] J. Huang, G. Yang, Z. Wang, and J. J. Park, “DiffusionPDE: generative PDE-solving under partial observation,” *NeurIPS*, vol. 37, 2024. arXiv:2406.17763.

[5] P. Du, M. H. Parikh, X. Fan, X.-Y. Liu, and J.-X. Wang, “Conditional neural field latent diffusion model for generating spatiotemporal turbulence,” *Nature Communications*, vol. 15, art. 10416, 2024.

[6] D. Shu, Z. Li, and A. B. Farimani, "A physics-informed diffusion model for high-fidelity flow field reconstruction," *Journal of Computational Physics*, vol. 478, 111972, 2023.

[7] M. Amoros-Trepat et al., "Guiding diffusion models to reconstruct flow fields from sparse data," *Physics of Fluids*, vol. 38, 015112, 2026.

[8] S. Bai, J. Z. Kolter, and V. Koltun, "An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling," arXiv:1803.01271, 2018.

[9] P. Kidger, J. Morrill, J. Foster, and T. Lyons, "Neural Controlled Differential Equations for Irregular Time Series," arXiv:2005.08926, 2020.

[10] D. P. Kingma and M. Welling, "Auto-Encoding Variational Bayes," arXiv:1312.6114, 2014.

[11] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-Resolution Image Synthesis with Latent Diffusion Models," *CVPR*, 2022; arXiv:2112.10752.

[12] Y. Song, P. Dhariwal, M. Chen, and I. Sutskever, "Consistency Models," arXiv:2303.01469, 2023.

[13] Farama Foundation, "Gymnasium Documentation: Create a Custom Environment and Vectorized Environments," `https://gymnasium.farama.org/`, accessed Aug. 2026.

[14] NVIDIA, "Isaac Lab Documentation: Manager-Based/Direct RL Environments and Vectorized Simulation," `https://isaac-sim.github.io/IsaacLab/`, accessed Aug. 2026.

[15] NVIDIA, "Isaac Sim API: apply forces and torques to rigid bodies," `https://docs.isaacsim.omniverse.nvidia.com/`, accessed Aug. 2026.

[16] NVIDIA, "NVIDIA Warp Documentation," `https://nvidia.github.io/warp/`, accessed Aug. 2026.

[17] NVIDIA, "TensorRT Documentation: Dynamic Shapes and Optimization Profiles," `https://docs.nvidia.com/deeplearning/tensorrt/`, accessed Aug. 2026.

[18] NVIDIA Developer, "Jetson Orin Nano Super Developer Kit / Jetson FAQ," `https://developer.nvidia.com/embedded/faq`, accessed Aug. 2026.

[19] 飞行器设计与自主控制实验室，"面向固定翼无人机获能滑翔的统一风场能量空间观测器：基于物理约束条件潜空间扩散模型的原理设计,"研究设计稿，2026 年 8 月。